

# Evaluación 1

José Adrián Rodríguez González

Universidad de Guanajuato  
ja.rodriguez.g@ugto.com

**Abstract.** Se analiza la contaminación PM 2.5 en la ciudad de Salamanca. Se ubican 3 estaciones, la de cruz roja, Nativitas y el DIF, de las cuales, solo dos de estas contienen el reactivo para medir el PM 2.5. Se realizan muestreos de la población original ya que existen alrededor de 100 mil registros y se muestrea con diferentes estrategias y se hacen pruebas estadísticas para validar la estrategia y cuantificar que tan buena estrategia de muestreo es

## 1 Introducción

La contaminación en la ciudad de Salamanca es un problema grave y se han realizado mediciones en el ambiente de la ciudad. Una de las variables a tomar en cuenta para verificar y observar la contaminación de la ciudad es con el PM 2.5. Se toman al rededor de 100000 muestras, de las tres estaciones que existen, solo dos toman en cuenta el PM 2.5 que es la estación de la cruz roja y el del DIF. Se generan 4 datasets

- Muestreo aleatorio A
- Muestreo aleatorio estratificado B
- Muestreo aleatorio sistemático C
- Política ambiental

Las muestras A,B,C poseen un tamaño de  $n = 1740$


## 2 Pruebas

### 2.1 Prueba 1

Para la prueba 1, se calcula la media, la mediana, la desviación estándar y el rango intercuartílico de la población completa, como se puede observar en la tabla 1

Los estadísticos dicen que la media esta un poco más hacia adelante que la mediana, mostrando un sesgo positivo, sin embargo, existe un valor alto de desviación junto al valor de IQR. La distribución de probabilidad mostrada en el gráfico de la figura 1, resulta mostrar que la población completa no tiene una distribución normal sino una distribución con un sesgo hacia la derecha. Esto también se verifica rápidamente con la gráfica de boxplot de la figura 1,

| mean  | median | std   | IQR   |
|-------|--------|-------|-------|
| 21.57 | 19     | 14.73 | 15.22 |

**Table 1.** Estadísticos principales para la población completa**Fig. 1.** Imagen con la distribución en forma de histograma, un boxplot y un gráfico Q-Q

que muestra la existen de muchos valores de outliers superiores al valor máximo tolerable del rango intercuartílico. Por la parte de la gráfica Q-Q, se observa que en los valores pequeños, existe un ligero sesgo superior de la línea, que se reduce hasta llegar al punto de la distribución en el que los puntos siguen la línea, pero a partir del cuartil teórico número 2, la distribución se dispara en los valores, mostrando el sesgo fuerte en la parte de arriba. Mediante la prueba de normalidad de shapiro wilk, se encontró un estadístico de 0.77 y un valor de p muy bajo cercano a 0.0, por lo tanto, se acepta la hipótesis alternativa, implicando que la distribución de la población completa es una distribución no normal

Es importante saber la distribución de probabilidad de la población completa porque nos da un mapa general de como se comportan los datos, y al aplicar nuestras estrategias de muestreo, lo ideal, es que las muestras sigan la distribución de donde se están extrayendo los datos. Así que la técnica de muestreo que escojamos, debe ser afín a la distribución original

## 2.2 Prueba 2

Para esta primera prueba que se realiza para validar que los muestreos son similares a la distribución de probabilidad, se proponen las siguientes hipótesis

$$H_0 : \mu_{muestral} = \mu_{poblacional} \quad (1)$$

$$H_1 : \mu_{muestral} \neq \mu_{poblacional} \quad (2)$$

Observando la tabla 2, se observa que para las estrategias A y C, no se rechaza la distribución, y analizando sus medias, son casi similares a la media poblacional calculada anteriormente, adicionalmente, el estadístico es casi similar en ambas estrategias junto a los valores de intervalos de confianza. Mientras que para la

|   | mean  | t_stat | p-value | ci lower | ci upper | reject H0 | conclusion       |
|---|-------|--------|---------|----------|----------|-----------|------------------|
| A | 21.48 | -0.24  | 0.80    | 20.77    | 22.20    | False     | No se rechaza H0 |
| B | 22.45 | 2.03   | 0.04    | 21.60    | 23.29    | True      | Se rechaza H0    |
| C | 21.69 | 0.36   | 0.71    | 21.03    | 22.36    | False     | No se rechaza H0 |

**Table 2.** Tabla de reporte de prueba t, intervalo de confianza y conclusión

estrategia B, si difiere entre ambas estrategias, tanto en medias, intervalos de confianza, y el estadístico, de esta manera, ya se tiene la primera sospecha de que la estrategia B no siga la distribución original.

### 2.3 Prueba 3

Para la prueba 3, se busca comparar cada una de las distribuciones entre sí. La muestra A con la B, la muestra A con la C y la muestra B con la C, de tal manera que se les aplica la prueba t para observar diferencias entre las distribuciones. Se hacen los siguientes supuestos para la prueba de Levene

$$H_0 : \sigma_1^2 = \sigma_2^2 = \dots = \sigma_k^2 \quad (3)$$

$$H_1 : \exists i, j \text{ tal que } \sigma_i^2 \neq \sigma_j^2 \quad (4)$$

Y para la prueba t

$$H_0 : \mu_{muestra1} = \mu_{muestra2} \quad (5)$$

$$H_1 : \mu_{muestra1} \neq \mu_{muestra2} \quad (6)$$

Por lo que se observa en la tabla 3, la comparación entre medias resulta en valores parecidos entre cada distribución, por medio de Levene se demuestra, que no existen diferencias significativas entre las varianzas, implicando que existe una homogeneidad entre las varianzas en las permutaciones de distribuciones a comparar. Por medio de la prueba t, se demuestra que no se rechaza la hipótesis nula, por lo tanto no hay evidencia suficiente para demostrar que las diferencias sean significativas entre las diferentes estrategias aleatorias, sin embargo, existen diferencias entre los valores de p, y se observa que cuando se analizan las distribución A contra B y B contra C, se observa que los valores tienden a acercarse al 0.05, implicando que podría haber una posible diferencia, pero que no es tan significativa para rechazar la hipótesis nula. Mientras que las estrategias A y B, obtienen los valores más altos tanto en Levene y el más cercano a cero en el estadístico t. La implicación de estas semejanzas es del posible uso de las estrategias A y C, y que se mantienen en observación la estrategia B

### 2.4 Prueba 4

Aquí se verifica el uso de alguna política ambiental ha afectado o demostrado beneficiar en el medio ambiente. Para esto, se toman las estaciones DIF y Cruz

| comparison | mean_1 | mean_2 | levne_p | type_test | t_stat    | p-value | reject_H0 | conclusion    |
|------------|--------|--------|---------|-----------|-----------|---------|-----------|---------------|
| 0 A vs B   | 21.487 | 22.452 | 0.172   | t-test    | -1.711850 | 0.087   | False     | No diferentes |
| 1 A vs C   | 21.487 | 21.698 | 0.790   | t-test    | -0.426    | 0.67    | False     | No diferentes |
| 2 B vs C   | 22.452 | 21.698 | 0.098   | t-test    | 1.37      | 0.16    | False     | No diferentes |

**Table 3.** Tabla con las pruebas, comparaciones de medias, pruebas de levene en varianzas y el tipo de test realizado segun levene

Roja, una muestra aleatoria o un intervalo de datos de ciertos años. Para este caso, se toma del 2017 al 2020 como las mediciones de PM 2.5 antes, y del 2021 al 2023, para las mediciones después. Esto para verificar en este caso si las políticas ambientales ocasionadas por la pandemia, demostró una mejoría o empeoró

Se realiza la prueba wilcoxon apareade con el siguiente supuesto

$$H_0 : \text{med}(X)_{diff} = 0 \quad (7)$$

$$H_1 : \text{med}(X)_{diff} \neq 0 \quad (8)$$

En la tabla 4, se observan los resultados del estadístico de Wilcoxon y del estadístico t. Como se observa por los valores de p, en ambos casos son mayores que 0.05, por lo tanto no se rechaza la hipótesis nula, implicando que no hubo diferencia de cantidad de PM 2.5 antes de pandemia y después de pandemia. Para estos casos, donde en las muestra se nota claramente una distribución sesgada y con varios outliers, la prueba Wilcoxon es más robusta, mientras que la prueba t es muy exacta siempre y cuando la distribución sea normal, sin embargo al ser una distribución no normal, esto implica que la prueba t no puede ser tomada a ciegas, mientras la Wilcoxon, al ser una prueba no paramétrico, no sufre con outliers, por lo tanto, la prueba más adecuada para este caso es la Wilcoxon

| w_stat    | w_p   | t_stat | t_p   |
|-----------|-------|--------|-------|
| 723344.00 | 0.180 | 0.272  | 0.785 |

**Table 4.** Métricas reportadas en la prueba 4, W estadísticos de wilcoxon, y comparación con prueba t

## 2.5 Prueba 5

Para la prueba 5 se realizan 4 análisis, primero 2 previos al análisis de 1 factor ANOVA, para poder determinar si los supuestos de esta prueba se cumplen, y observar la normalización de los residuales. Los primeros supuestos que se deben de hacer, son los siguientes

$$H_0 : \mu_A = \mu_B = \mu_c \quad (9)$$

Mediante la tabla 5, se observan los resultados obtenidos tras una prueba de Levene, de la cual se demuestra que los valores de varianzas son similares entre cada una de las estrategias implementadas, ya que el valor de  $p$ , es mayor que 0.05, aceptando la hipótesis nula de esta prueba. Así que el primer supuesto de la prueba ANOVA se aprueba

|   | levене_stat | levене_p | equal_variance |
|---|-------------|----------|----------------|
| 0 | 1.697230    | 0.183291 | True           |

**Table 5.** Tabla de la prueba de levene

Para la siguiente prueba, se determina si cada una de las distribuciones son normales, mediante la tabla 6, se observa que todas las estrategias no siguen una distribución normal ya que el valor de  $p$  fue demasiado bajo casi cercano a 0, por lo tanto tiene un fuerte sesgo. Esto ya alerta de que la prueba ANOVA, posiblemente no sea suficiente o no sea muy confiable dado a que la distribución obtenida por las tres estrategias no son normales.

|   | shapiro_stat | shapiro_p | normal |
|---|--------------|-----------|--------|
| A | 0.756971     | 0.000000  | False  |
| B | 0.640315     | 0.000000  | False  |
| C | 0.828858     | 0.000000  | False  |

**Table 6.** Prueba de shapiro wilk realizada para cada estrategia de muestreo

Sin embargo, se realiza la prueba y mediante la tabla 7, y se obtiene que el valor de  $p$  mayor a 0.05, implicando que la hipótesis nula se acepta, demostrando que las varianzas entre las 3 muestras son casi similares

| f_stat | f_p   | reject_H0 |
|--------|-------|-----------|
| 1.789  | 0.167 | False     |

**Table 7.** Resultados obtenidos por la prueba ANOVA

Finalmente, se debe de analizar la normalidad de los valores residuales. El valor  $p$  observado en tabla 8, muestra que la prueba de Shapiro Wilk de normalización fue rechazada la hipótesis nula, de tal manera que aquí si se puede afirmar que no sigue una distribución normal.

Por medio de estos tres puntos a analizar, (normalidad en residuales, varianza similar, normalidad en datos de entrada), y es que, a pesar de que los datos de

|   | shapiro_stat | shapiro_p | normal |
|---|--------------|-----------|--------|
| A | 0.756971     | 0.000000  | False  |
| B | 0.640315     | 0.000000  | False  |
| C | 0.828858     | 0.000000  | False  |

**Table 8.** Prueba de Shapiro Wilk realizada para cada estrategia de muestreo en sus residuales

entrada no sean normales, sin embargo si los residuales fueran normales y la varianza es homogénea, esto implica que el test de ANOVA es confiable. Sin embargo, los valores residuales resultaron en ser no normales, por lo tanto, la estrategia ANOVA puede verse afectada debido a que necesita y asume normalidad y es susceptible su estadístico a los outliers

## 2.6 Prueba 6

Ya que las pruebas paramétricas requieren y asumen normalidad, las pruebas no paramétricas pueden sobrevivir antes problemas que no tenga normalidad. Y es precisamente el caso del método de Kruskal Wallis que permite ser usado en este tipo de escenarios. Al realizarse la prueba con las estrategias de muestreo, se asume primeramente los siguiente

$$H_0 : \text{med}(A, B, C) = 0 \quad (10)$$

$$H_1 : \text{med}(A, B, C) \neq 0 \quad (11)$$

| h_stat | p_value | reject_H0 |
|--------|---------|-----------|
| 2.0496 | 0.3588  | False     |

**Table 9.** Valores residuales: análisis de normalización

Para la tabla 9, se observa que el valor del p value es mayor que 0.05, implicando que se toma la hipótesis nula, por lo tanto, se dice que las medianas son casi similares y si observamos la tabla de post hoc dunn, vemos que en todos los casos no hay evidencia suficiente para rechazar la hipótesis nula, ya que cada valor dentro de la tabla representa un p value. El que menos p value tiene es el B, pero los demás tienden casi a 1. El resultado obtenido en Kruskal Wallis con respecto a t student, difiere en el caso del dataset B, por lo tanto, podría implicar que el caso B tiene una alta presencia de asimetría y datos outliers

## 2.7 Prueba 7

Para la prueba de chi en este ejemplo, se toma en cuenta que los valores sanos de PM 2.5 debe de ser  $50\mu g/m^3$ , de tal manera que se toma en cuenta que aquellos

|   | A        | B        | C        |
|---|----------|----------|----------|
| A | 1.000000 | 0.490782 | 0.977782 |
| B | 0.490782 | 1.000000 | 1.000000 |
| C | 0.977782 | 1.000000 | 1.000000 |

**Table 10.** Matriz de Dunn

valores que sean mayores que este 50, serán considerados como si, mientras los que sean menores, serán considerados como no. Para la prueba se toman los siguientes supuestos

$$H_0 : \text{Los excesos de PM}_{2.5} \text{ son independientes de la estrategia de muestreo} \quad (12)$$

$$H_1 : \text{Los excesos de PM}_{2.5} \text{ no son independientes de la estrategia de muestreo} \quad (13)$$

Se hizo la siguiente tabla de contingencia, donde las columnas son el *si* y el *no*, mientras que los valores de las filas, son las estrategias, esto se puede observar en la tabla 11.

|   | si | no   |
|---|----|------|
| A | 75 | 1665 |
| B | 71 | 1669 |
| C | 62 | 1678 |

**Table 11.** Tabla de contingencia

Para realizar el cálculo de la prueba de chi cuadrado, se necesita calcular la tabla de frecuencias que se puede observar en la tabla

|   | si        | no          |
|---|-----------|-------------|
| A | 69.333333 | 1670.666667 |
| B | 69.333333 | 1670.666667 |
| C | 69.333333 | 1670.666667 |

**Table 12.** Tabla de frecuencias

Finalmente, en la tabla número 3, se observan los resultados obtenidos tras la prueba chi y observamos que el valor de p es casi cercano pero sigue siendo mayor que el valor de 0.05, implicando que se acepta la hipótesis nula y por lo tanto, los excesos de PM 2.5 son independientes de la estrategia de muestreo

| chi2  | p_value | dof | reject_H0 |
|-------|---------|-----|-----------|
| 1.331 | 0.513   | 2   | False     |

**Table 13.** Tabla de resultados para chi cuadrada

## 2.8 Prueba 8

Analizando los datos de forma gráfica nos da una perspectiva diferente sobre como se están comportando los datos, En la figura 2 se pone en comparación los 4 csv, analizando el boxplot, dado a las perspectivas de los datos, el conjunto A y C logran parecerse mucho, mientras que el conjunto B tiene más outliers, si vemos el gráfico Q-Q, todas las curvas intentan asemejarse a lo realizado por el la curva de población completa, sin embargo, en las gráficas de histogramas y de errores, se nota y se puede visualizar de mejor forma cuales distribuciones si logran parecerse. La gráfica de histogramas, muestra de color azul el histograma de la población completa y observamos que el Verde y el amarillo, además de parecerse mucho entre si, se encuentran muy alineados con la distribución de población completa, mientras que la roja, que es la distribución B, se encuentra más desfasada de las demás. Si se observan las gráficas de error, se comprueba que las distribuciones A y C son muy parecidas mientras que la distribución B, tiene una media mayor que las otras estrategias de muestreo Visualmente concluimos que la distribución roja tiene más asimetrías mientras que las distribuciones A y B muestran mayor estabilidad en la forma en como se comportan los datos


## 2.9 Prueba 9

Para la prueba 9, se analiza en las tres estrategias de muestreo, la estimación del error, la preservación de la distribución y la consistencia del chi cuadrado. Todo esto con respecto a la población original para así, encontrar cual de las diferentes estrategias de muestreo resulta ser la más parecida a la distribución original. Se define un score tal que:

$$score = -error + ks_p + \chi_p^2 \quad (14)$$

Mediante ese score, busca penalizar el error de medias con respecto a la distribución original. Podemos observar que en la estrategia A, a pesar de que en la prueba  $\chi$ , tuvo un valor de 0.05, no le afecto tanto, ya que el error de la mediana es el más bajo con respecto a todas las demás estrategias, sin embargo, la estrategia B fue la más perjudicada por su diferencia de media entre la población original y esta estrategia. Por la parte de la prueba chi de Kruskal Wallis, se denota que el que tuvo un valor p más pequeño fue la estrategia B, mientras que el que tuvo mayor fue la estrategia C. Por lo tanto, al rankear, podemos decir que la estrategia que mejor se asimila a la distribución original para este problema específicamente, es la estrategia C, mientras que el que no es tan recomendable es la estrategia B. A lo largo de las diversas pruebas, se ha comprobado que los





**Fig. 2.** Dashborad con histogramas, boxplots,q-q plots y gráficos de error

valores de B, mostraban diferencias con respecta a las otras estrategias y que era tentativamente el que era más diferente. Por lo que para el pipeline de monitoreo diario, recomienda la estrategia C, dado a las pruebas estadísticas previas y a los resultados comparativos en la tabla 14 con respecto a la población original

| strategy | mean_error | ks_pvalue | chi_pvalue | final_score | rank     |
|----------|------------|-----------|------------|-------------|----------|
| C        | 0.122053   | 0.717166  | 0.825196   | 1.420309    | 1.000000 |
| A        | 0.089388   | 0.369283  | 0.054284   | 0.334178    | 2.000000 |
| B        | 0.876176   | 0.197882  | 0.161409   | -0.516886   | 3.000000 |

**Table 14.** Tabla con los rankeos

## 2.10 Prueba 10

Para esta prueba, se auditan las pruebas previas y se orquestan las estrategias, sin embargo, añadiendo las medias muestrales, la población y la prueba t, en la tabla 15, se observan las medias muestrales y la media población y se afirma

lo visto en la prueba 9, en donde la estrategia C contiene una diferencia de medias un poco más pronunciada con respecto a la población original y las demás poblaciones muestreadas. Y observando los resultados obtenidos por la prueba t, la distribución B muestra el rechazo de la hipótesis nula, implicando que si existe una diferencia significativa, algo que se constata con respecto a lo observado con la media muestral y la media poblacional. La recomendación se basa en cuantas p mayores a 0.05 hay, y en el caso de la estrategia B, demuestra que tiene un sesgo.

| estrategia | media_muestral | media_poblacional | pvalue_t | pvalue_ks | pvalue_chi | recomendacion        | score |
|------------|----------------|-------------------|----------|-----------|------------|----------------------|-------|
| A          | 21.487209      | 21.576597         | 0.806076 | 0.369283  | 0.054284   | Buena representacion | 3     |
| B          | 22.452773      | 21.576597         | 0.042130 | 0.197882  | 0.161409   | Posible sesgo        | 2     |
| C          | 21.698651      | 21.576597         | 0.717553 | 0.717166  | 0.825196   | Buena representacion | 3     |

**Table 15.** Las tres estrategias, con diferentes métricas y una posible recomendación

### 3 Conclusiones

Analizar diferentes estrategias de muestreo es importante al intentar tomar solo una n cantidad de elementos, y al encontrar la mejor selección de estrategia, se pueden aplicar algoritmos de inferencia, regresión o de clasificación, ya que mediante pruebas estadísticas, demuestran que pueden generalizar bien los datos completos. En este caso, se recomienda más la estrategia C, pero la A también sigue siendo una buena opción si se quiere una metodología rápida, mientras que la B, debido a que lo hace proporcionalmente a las estaciones, puede introducir sesgos, haciendo que la población completa sea diferente