

Tipos de Datos

Barroso Solorzano Jorge Antonio¹, Illescas Flores Marco Uriel¹, Rodríguez González José Adrián¹, Valdés Velázquez Héctor Emilio¹

¹Ingeniería de Datos e Inteligencia Artificial, Universidad de Guanajuato, Guanajuato SAL 36787, MEX, 20 de febrero 2026; Profesor: Felipe de Jesús Trujillo Romero; Materia: Análisis de Datos.

Abstract. Se trabajó con distintos tipos y formatos de datos, predominando aquellos datos en forma de grafo y de mapas. Atacando problemáticas de ecología y salud en la ciudad de México, siguiendo de un análisis exhaustivo de la venta de botellas en México y finalmente con problemas de grafos, un recorrido óptimo de aeropuertos y la creación de una base de datos de universidades, todas logrando ser culminadas mostrando sus respectivas dificultades.

Keywords: *mapa, grafo, serie de tiempo.*

1 Introducción

En esta ocasión, se realizaron varias tareas de análisis de datos, enfocadas a los tipos de datos de grafos, mapas y series de tiempo. Para el primer problema, se observa el análisis de estaciones de bicicletas en la ciudad de México, después, el análisis de centros de salud y observar que colonias están cubiertas por este servicio médico.

El análisis de series de tiempo no se queda atrás y también resulta importante para el análisis de ventas de botella en una productora china. El reto que proporcionó el contar con un intervalo de tiempo limitado de 10 meses, contando con solo 8 meses reales. Después, analizando varios puntos de aeropuertos en diversas zonas del mundo y encontrando sus rutas óptimas. El último realiza una recopilación de datos en el formato de RDF para obtener una contextualización de los lugares de procedencia y años de fundación en universidades, principalmente de la Ciudad de México. Utilizando tecnologías como Python y librerías propias para el análisis de este tipo de datos.

2 Metodología

2.1 Actividad 1: Visualización interactiva de puntos geográficos con Folium

El objetivo de esta actividad fue representar información georreferenciada mediante visualización cartográfica, con el propósito de identificar patrones espaciales en la distribución de estaciones del sistema de bicicletas públicas Ecobici en la Ciudad de

México. Para ello, se emplearon técnicas de limpieza de datos, análisis espacial y visualización.

Carga y procesamiento de datos.

Se cargó el conjunto de datos en formato CSV y posteriormente se realizó un proceso de depuración orientado a garantizar la validez espacial de los registros. Se eliminaron observaciones con valores faltantes en las variables de latitud y longitud, ya que estas impedían su representación cartográfica.

Adicionalmente, se implementó una validación por rango geográfico para descartar coordenadas erróneas o fuera del área de estudio. Este filtrado se basó en límites aproximados de la ciudad (latitud entre 19.0 y 19.6; longitud entre -99.3 y -99.0), permitiendo conservar únicamente estaciones ubicadas dentro de la zona urbana. Esta etapa fue relevante debido a la ausencia de un campo explícito de validación espacial en el dataset.

Agrupamiento espacial.

Para esta sección, se siguieron dos modelos de aprendizaje no supervisado, el primero es un K-Means. Este método de aprendizaje no supervisado permite segmentar el espacio en regiones donde la proximidad entre estaciones es máxima respecto a sus centroides, facilitando la detección de concentraciones operativas del sistema. Este algoritmo utiliza la métrica euclidiana para realizar el cálculo de distancias.

La segunda técnica que se utilizó fue DBSCAN (3), este algoritmo requiere de tres parámetros, el primero es un valor ϵ , que corresponde a una pequeña distancia donde se encontrarán los elementos, que en este caso son las estaciones de bicicletas. El segundo parámetro es la cantidad mínima de muestras en clúster y finalmente, la métrica haversine(2), que se basa en la ecuación (1)

$$(1) \quad 2 \arcsin \left[\sqrt{\left(\sin^2 \left(\frac{(x_{lat} - y_{lat})}{2} \right) \right) + \cos(x_{lat}) \cos(y_{lat}) \sin^2 \left(\frac{(x_{lon} - y_{lon})}{2} \right)} \right]$$

Esta ecuación se basa enteramente en las coordenadas de latitud y longitud de la tierra, resultando ser útiles para medir distancias en la tierra. Con estos parámetros, se puede iniciar el algoritmo de DBSCAN. Al realizar los clústeres, para determinar la región de densidad, se utiliza el algoritmo de Convex Hull para generar un polígono que encierre las regiones con alta densidad de bicicletas.

Construcción del mapa interactivo.

Se generó un mapa dinámico que integra múltiples capas de información:

- **Marcadores circulares proporcionales:** Cuyo tamaño representa la disponibilidad de bicicletas en cada estación cuando dicha variable está presente.
- **Agrupación visual (marker clustering):** Permite explorar la densidad de estaciones de forma escalable según el nivel de zoom.

- **Coloreado por clúster:** Se asigna una tonalidad distinta a cada grupo identificado por K-Means para facilitar su diferencia espacial.
- **Mapa de calor (heatmap):** Utilizado como representación continua de densidad para resaltar zonas con alta concentración de estaciones.

El resultado final se exportó como un archivo HTML interactivo, lo que permite su exploración en navegador.

Consideraciones técnicas.

La principal decisión metodológica consistió en definir límites geográficos válidos para filtrar coordenadas, ya que estos no estaban especificados en la fuente de datos. Este paso fue esencial para evitar sesgos visuales provocados por registros atípicos.

2.2 Actividad 2: Análisis de buffers y proximidad con GeoPandas

Esta actividad tenía como objetivo, analizar la accesibilidad a la infraestructura de salud en la Ciudad de México mediante el uso de operaciones de tipo “espacio”. Utilizando la librería “geopandas”, se buscó determinar qué proporción de las áreas residenciales (representadas por las unidades habitacionales) cuentan con cobertura médica dentro de un radio de 1 kilómetro, apoyado de la creación de buffers y el cálculo de intersecciones.

Carga y procesamiento de datos.

Se importaron los archivos vectoriales (shapefiles) correspondientes a los centros de salud (indicados como puntos más adelante) y las unidades habitacionales (polígonos). Se utilizó el dataset oficial de unidades habitacionales como la variable proxy de las zonas urbanas pobladas, ya que este proporciona un nivel de detalle y precisión para indicar la concentración real. Ambos datasets fueron cargados y almacenados con GeoDataFrames.

Transformación del Sistema de Coordenadas

Dado que los datos originales se encuentran en grados (Latitud y Longitud), los GeoDataFrames fueron re proyectados al sistema UTM Zona 14N (EPSG:32614), sistema estándar técnico utilizado para la geolocalización, cartografía y navegación en la región central del territorio mexicano, abarcando también a Ciudad de México.

Generación de Zonas de Cobertura

Se aplicó una función de tipo buffer con el parámetro 1000 a la geometría de los hospitales para crear un radio de influencia de 1 kilómetro alrededor de cada centro de salud. Posteriormente, se unificaron dichas áreas para la optimización de su cruce.

Análisis de Intersección

Se evaluó que unidades habitacionales se solapaban total o parcialmente con la macro-zona de cobertura generada, clasificándolas de manera binaria:

- **Cubierta:** La unidad habitacional interseca con la zona de cobertura.
- **No cubierta:** La unidad habitacional queda completamente fuera de la zona de cobertura.

Dicha clasificación fue utilizada para su posterior cuantificación y visualización.

2.3 Actividad 3: Descomposición y modelado ARIMA con statsmodels

Para esta actividad se realizó un análisis de series temporales completo de datos de venta de vinos utilizando la metodología SARIMA (Seasonal Auto Regressive Integrated Moving Average). El proyecto se dividió en cuatro fases principales: descomposición de la serie, selección automática de parámetros, generación de pronósticos y evaluación del modelo predictivo.

Preparación y generación de datos

El dataset inicial consistía en 8,141 registros de transacciones de venta con información de cantidad de ventas en 30 días, cantidad de reseñas y otras métricas. Este conjunto contenía 1,060 valores faltantes (13.02%) distribuidos principalmente en la columna de cantidad de reseñas. Se realizó imputación de valores nulos utilizando la mediana (203 reseñas) como valor de reemplazo.

Posteriormente, se agregaron los datos por fecha, sumando las ventas en períodos de 30 días. Este proceso resultó en 8 observaciones mensuales con periodicidad consistente que abarcaban desde mayo de 2018 hasta febrero de 2019. Durante este período se identificaron dos meses faltantes (junio y octubre de 2018), los cuales fueron interpolados linealmente en base a los valores adyacentes para garantizar continuidad temporal.

Para aumentar la cantidad de observaciones disponibles para el modelado analítico, se implementó un generador sintético basado en ARIMA. El procedimiento consistió en:

1. Ajustar un modelo ARIMA(1,1,1) a las 8 observaciones reales.
2. Generar 52 puntos adicionales mediante pronóstico iterativo con inyección de ruido controlado (0.2 veces la desviación estándar de residuos).
3. Aplicar un filtro de no-negatividad para asegurar que las ventas sintetizadas fueran realistas. El resultado final fue una serie temporal de 62 observaciones (8 reales + 2 interpoladas + 52 sintéticas) distribuidas desde mayo de 2018 hasta junio de 2023.

Análisis de descomposición

Se aplicó la descomposición clásica aditiva de la serie temporal con periodicidad estacional de 12 meses. Esta técnica permitió separar la serie en cuatro componentes independientes:

1. La serie original.
2. La tendencia de largo plazo.
3. El patrón estacional repetitivo.
4. Los residuos o componentes irregulares no explicados.

Selección de parámetros SARIMA

Se realizó una búsqueda exhaustiva en cuadrícula (grid search) sobre el espacio de parámetros posibles para la familia de modelos SARIMA. Se evaluaron 216 combinaciones diferentes variando los órdenes $(p, d, q) \in [0, 2]$ para la parte no estacional y $(P, D, Q) \in [0, 1]$ para la componente estacional con período $m = 12$ meses.

Cada modelo fue entrenado en el conjunto completo de 62 observaciones y su calidad fue evaluada mediante el criterio de información de Akaike (AIC). Los diez modelos con menor AIC fueron registrados para análisis comparativo. El mejor modelo seleccionado fue SARIMA(0,1,2) $\times$ (0,1,1,12), lo que indica: cero términos autorregresivos no estacionales, una diferenciación de orden uno, dos términos de media móvil, cero componentes autorregresivos estacionales, una diferenciación estacional, y un término de media móvil estacional.

Pronóstico y evaluación

Utilizando el modelo óptimo identificado, se generaron pronósticos para los siguientes 12 meses (julio 2023 a junio 2024) incluyendo intervalos de confianza al 95%. Adicionalmente, se realizó una evaluación retrospectiva del desempeño del modelo mediante validación hacia atrás (backtesting), utilizando los últimos 12 meses observados (julio 2022 a junio 2023) como conjunto de prueba y los 50 primeros meses como conjunto de entrenamiento.

2.4 Actividad 4: Recorridos y caminos óptimos en grafos

El objetivo de esta actividad fue modelar y analizar la red de rutas aéreas internacionales utilizando datos abiertos del proyecto OpenFlights. Mediante la implementación de la librería networkx en Python, se buscó construir un grafo dirigido para evaluar la conectividad global, calcular distancias topológicas (diámetro) e implementar el algoritmo de Dijkstra para la optimización de rutas de vuelo, tanto por el mínimo de escalas como por la distancia geográfica más corta.

Ingesta y Depuración de los Datos

Se importaron los datasets de aeropuertos (nodos) y rutas (aristas) directamente desde sus repositorios mediante pandas. Se realizó una limpieza inicial para eliminar registros con identificadores nulos y garantizar la integridad referencial entre rutas y aeropuertos existentes.

Construcción del Grafo Dirigido

Se instanció un modelo de red direccional, dado que las rutas aéreas no siempre son bidireccionales de manera simétrica, cada nodo fue enriquecido con atributos geospaciales (latitud y longitud).

Distancia Geográfica

Para calcular la ruta "más rápida", fue necesario asignar un peso a cada arista. Se implementó la fórmula trigonométrica de *Haversine* para calcular la distancia ortodrómica (en kilómetros) entre las coordenadas de origen y destino, considerando la curvatura de la Tierra. Este valor métrico se asignó como el atributo `weight` de cada conexión.

Algoritmo Dijkstra

Se implementaron dos enfoques de búsqueda de caminos óptimos:

- **Ruta más corta:** Con una función específica que ignora los pesos, se obtuvo el trayecto con el menor número de saltos (escalas).
- **Ruta más rápida:** Se aplicó la función específica de Dijkstra para obtener y calcular la distancia en kilómetros como factor de optimización.

2.5 Actividad 5: Grafos de conocimiento con RDFLib

Para esta actividad, se tiene que crear un grafo de conocimiento en el formato RDF con las universidades mexicanas, utilizando la siguiente nomenclatura:

```
<UNAM> <ubicada_en><Ciudad_de_Mexico>
<Tec_de_Monterrey><fundada_en>''1943''
```

Todas las consultas serán almacenadas en un grafo de tripletas RDF y se realizarán consultas SPARQL para listar todas las universidades en CDMX y las universidades fundadas antes de 1950.

Se encontró la siguiente base de datos que contiene las universidades a nivel nacional (1), así como también, ubicaciones, fechas de fundación, nombres de municipio y de estado a su vez como latitud y longitud. Sin embargo, solo fue necesario el tratamiento del formato de fecha de fundación y el uso de las columnas de los nombres de las universidades, junto al de los municipios, intercambiando el nombre de alcaldías en Ciudad de México a solo el nombre de la ciudad de México.

3 Resultados

3.1 Actividad 1

La primera visualización que se puede observar con el algoritmo de DBSCAN, es un mapa general que muestra el fenómeno global de la densidad de bicicletas en la Ciudad de México. Se puede observar que, en las zonas de la Condesa, y Chapultepec, existe una mayor cantidad de estaciones de bicicletas y que su distancia es relativamente corta.

Existen otros clústeres más pequeños que están dentro del clúster rojo gigante, como el verde, azul y púrpura, mostrando colonias en las que sus estaciones de bicicletas se encuentran más cerca que en las de la región principal. Adicionalmente existen dos regiones al norte de la ciudad de México colindando con el estado de México que son más reducidas en cuestión de cantidad de estación de bicicletas.

Existen regiones en las que las estaciones de bicicletas no forman parte de algún clúster, esto porque el algoritmo las considera como ruido al no estar cerca del poder afluencia de agrupaciones circundantes. La figura 1 se puede apreciar este pequeño análisis. El DBSCAN nos permite visualizar de forma general el fenómeno de las estaciones, respetando la geometría de la tierra. Sin embargo, con la aplicación del siguiente algoritmo, se puede apreciar un clusterizador/segmentador de regiones de estaciones de bicicletas.




Fig. 1. Mapa con el algoritmo de DBSCAN y convex hull, el primer algoritmo define los clústeres y el segundo define las regiones dado a los clústeres.

La visualización generada permitió analizar la distribución espacial del sistema Eco-bici desde una perspectiva exploratoria e interactiva.




Fig. 2. Mapa de interactivo de la Ciudad de México con las estaciones de Ecobici. La visualización muestra la distribución espacial de los puntos georreferenciados, con círculos proporcionales al número de bicicletas disponibles. Los clústeres de alta densidad se representan con colores distintos, permitiendo identificar zonas con mayor concentración de estaciones.

Identificación de zonas de alta densidad

El mapa de calor evidenció una concentración significativa de estaciones en áreas centrales de la ciudad, lo que sugiere una planificación orientada a maximizar la cobertura en zonas con alta demanda de movilidad, conectividad urbana y actividad económica. En contraste, las zonas periféricas mostraron una dispersión considerablemente menor.

Interpretación del agrupamiento espacial

El modelo de K-Means segmentó las estaciones en cinco regiones principales con características geográficas diferenciadas. Estos clústeres reflejan patrones operativos del sistema:

- Clústeres centrales con alta proximidad entre estaciones.

- Clústeres intermedios que actúan como zonas de transición.
- Clústeres más dispersos en áreas de menor densidad urbana.

La superposición de colores permite observar que los límites entre regiones no son estrictamente administrativos, sino funcionales, lo cual confirma que el algoritmo identifica estructuras espaciales.

Exploración multiescala mediante interacción

El agrupamiento dinámico de marcadores facilitó el análisis a diferentes niveles de detalle. A escalas amplias se observan concentraciones globales, mientras que al acercarse se revelan configuraciones locales de estaciones individuales. Esta característica mejora la interpretabilidad frente a mapas estáticos, donde la sobreposición de puntos suele dificultar el análisis.



Fig. 3. Exploración multiescala de las estaciones de Ecobici en la Ciudad de México. El agrupamiento dinámico de marcadores permite analizar la distribución espacial a diferentes niveles de detalle. A escalas amplias se observan concentraciones globales, mientras que al acercarse el zoom se revelan configuraciones locales de estaciones individuales.

Limitaciones observadas


- El análisis depende de la calidad de las coordenadas originales. Fue necesario aplicar filtros para garantizar consistencia espacial.
- La visualización es principalmente exploratoria, no incorpora variables temporales ni modelos de demanda.

3.2 Actividad 2

El análisis espacial permitió observar los siguientes resultados sobre 15158 unidades habitacionales analizadas:

Table 1. Unidades habitacionales analizadas.

Unidades con cobertura	8638 unidades habitacionales
Unidades sin cobertura	6520 unidades habitacionales
Porcentaje de cobertura	56.99%

**Fig. 4.** Mapa de puntos de la cobertura hospitalaria en la Ciudad de México.

Los resultados indican que, estadísticamente, un 43.01% de las concentraciones con viviendas analizadas se encuentran en una zona con nula atención y accesibilidad a la atención primaria (unidades representadas de color rojo), obligando a los residentes de dichas delegaciones a recorrer distancias superiores al kilómetro, mientras que las delegaciones más céntricas o privilegiadas monetariamente, cuentan con dichas unidades en una menor distancia (unidades representadas de color verde).

Es evidente que existe una centralización en la ubicación de la infraestructura sanitaria. Las zonas céntricas presentan una alta densidad de hospitales con áreas de cobertura que se solapan, generando un fácil acceso peatonal en esa concentración.

Por el contrario, la periferia de la ciudad muestra marcados clústeres en rojo, evidenciando una desigualdad en la distribución de los servicios de salud frente a las zonas residenciales.

Se deben considerar dos limitantes metodológicas del modelo utilizado:

- **Aproximación demográfica:** El dataset utilizado mapea polígonos de edificaciones sin incluir un censo demográfico por unidad. Por lo tanto, el

56.99% obtenido representa estrictamente la proporción de infraestructura de vivienda cubierta. Aunque se utiliza como una variable representativa (proxy) de la población asumiendo una densidad uniforme, es una estimación que no refleja el conteo exacto de habitantes.

- **Accesibilidad real:** El uso de buffers circulares asume una accesibilidad en línea recta (distancia euclidiana). En la realidad, un trayecto de un 1 kilómetro rara vez es directo; el desplazamiento de las personas se ve condicionado por la infraestructura ya existente y las barreras físicas como las avenidas, barrancos, carreteras, puentes y cruces peatonales.

3.3 Actividad 3

Descomposición de la serie temporal

La descomposición clásica reveló las siguientes características estadísticas de la serie original:

Table 2. Estadísticas de la serie original y sus componentes.

ESTADÍSTICAS DE LA SERIE ORIGINAL Y COMPONENTES	
ESTADISTICOS	
Media	513,425 botellas
Desv. Estándar	119,511 botellas
Mínimo	128,671 botellas
Máximo	642,161 botellas
Rango	513,490 botellas
TENDENCIA	
Mínimo	372,850 botellas
Máximo	571,860 botellas
ESTACIONALIDAD	
Amplitud	71,615 botellas
RESIDUOS	
Media	7,352 botellas
Desv. Estándar	45,147 botellas



Fig. 5. La descomposición clásica de la serie temporal se visualiza en cuatro paneles consolidados que revelan la estructura subyacente de los datos de venta.

El panel superior muestra la serie original con sus fluctuaciones irregulares entre 128K y 642K botellas.

El segundo panel exhibe la tendencia suavizada, que evidencia un trayecto ascendente desde 372K hasta 571K botellas, capturando el movimiento de largo plazo del mercado.

El tercer panel aísla el patrón estacional repetitivo, con una amplitud de $\pm 71K$ botellas alrededor de la línea cero, revelando picos recurrentes que coinciden con períodos de alta demanda (principalmente febrero).

El panel inferior representa los residuos o componentes irregulares, que fluctúan alrededor de cero con desviación estándar de 45K botellas, indicando una descomposición efectiva de los patrones principales México.

Selección del modelo SARIMA

La búsqueda exhaustiva evaluó 216 combinaciones de parámetros SARIMA. Los diez mejores modelos ordenados por criterio de información de Akaike fueron:

Table 3. Top 10 modelos SARIMA según AIC.

Top	MODELO ARIMA	AIC	Diferencia respec- to al mejor modelo
1	SARIMA (0,1,2)x(0,1,1,12)	819.31	0.00

2	SARIMA (1,1,2)x(0,1,1,12)	820.06	0.75
3	SARIMA (0,1,2)x(1,1,1,12)	820.93	1.62
4	SARIMA (1,1,2)x(1,1,1,12)	823.28	3.97
5	SARIMA (2,1,2)x(0,1,1,12)	823.28	4.52
6	SARIMA (2,1,2)x(1,1,1,12)	825.83	6.52
7	SARIMA (2,2,2)x(1,1,0,12)	832.54	13.23
8	SARIMA (1,0,2)x(1,1,1,12)	833.49	14.18
9	SARIMA (1,0,2)x(0,1,1,12)	833.86	14.55
10	SARIMA (0,0,2)x(1,1,1,12)	834.86	15.55

Interpretación del modelo seleccionado SARIMA(0,1,2)x(0,1,1,12):

- **p = 0:** Sin términos autorregresivos en la parte no estacional.
- **d = 1:** Una diferenciación de orden uno para remover tendencia.
- **q = 2:** Dos términos de media móvil para captar shocks corto plazo.
- **P = 0:** Sin autorregresión en la componente estacional.
- **D = 1:** Una diferenciación estacional para remover patrón anual.
- **Q = 1:** Un término de media móvil estacional.
- **m = 12:** Período estacional de 12 meses.




Fig. 6. Los gráficos de diagnóstico del modelo SARIMA(0,1,2)x(0,1,1,12) permiten validar la adecuación estadística del modelo seleccionado. La gráfica de Autocorrelación (ACF) muestra barras que decaen rápidamente hacia cero, indicando que las diferencias especificadas en el modelo ($d=1$, $D=1$) han removido efectivamente las dependencias temporales sistemáticas. La gráfica de Autocorrelación Parcial (PACF) presenta un patrón similar sin picos significativos fuera de los intervalos de confianza, confirmando que los patrones autorregresivos residuales son mínimos.

El gráfico de residuos versus tiempo muestra una dispersión homogénea alrededor de cero sin tendencias discernibles, evidenciando que el modelo ha capturado los patrones principales. El histograma de residuos aproxima una distribución normal, validando el supuesto fundamental de los modelos ARIMA. En conjunto, estos diagnósticos confirman que SARIMA(0,1,2)x(0,1,1,12) es un modelo adecuado y válido para pronóstico venta

El modelo SARIMA(0,1,2)x(0,1,1,12) generó pronósticos para julio 2023 a junio 2024 con intervalos de confianza al 95%. Los resultados se presentan en la siguiente tabla:

Table 4. Pronóstico SARIMA a 12 meses (Julio 2023 - Junio 2024).

Fecha	Pronóstico	LI_95%	LS_95%
2023-07	586572	500720	672424
2023-08	572411	482361	662462
2023-09	564569	473416	655723
2023-10	566765	474522	659008

2023-11	535080	441760	628401
2023-12	549474	455089	643860
2024-01	560708	465270	656146
2024-02	590019	493540	686499
2024-03	577608	480098	675118
2024-04	522686	424156	621216
2024-05	572679	473140	672218
2024-06	560860	460322	661398




Fig. 7. El gráfico de pronóstico integra la serie histórica completa (mayo 2018 a junio 2023) con la proyección futura de 12 meses (julio 2023 a junio 2024). La línea azul oscuro representa los datos históricos observados, exhibiendo la volatilidad, tendencia y patrón estacional capturados durante el período de entrenamiento. A partir de junio 2023, la línea de pronóstico en color diferente (típicamente rojo o verde) continúa desde el último punto observado, proyectando valores esperados para el siguiente año. El pronóstico oscila entre 522K y 590K botellas, manteniéndose coherente con el rango histórico. Las bandas sombreadas alrededor del pronóstico representan los intervalos de confianza al 95%, que se amplían conforme aumenta el horizonte de predicción, reflejando la incertidumbre gradual inherente a pronósticos a largo plazo. Esta visualización facilita la toma de decisiones operativas al proporcionar límites superior e inferior realistas para la planificación de demanda y gestión de inventario.

Evaluación del modelo.

Se realizó validación retrospectiva (backtesting) utilizando los últimos 12 meses del período de entrenamiento como conjunto de prueba (julio 2022 a junio 2023).

Los resultados de desempeño fueron los siguientes:

Table 5. Métricas del error global.

Métrica	Valor
RMSE Error Cuad. Medio	11749 botellas
MAE Error Absoluto Medio	11178 botellas
Error promedio	-2.04% (sesgo del modelo)
Desv. Estándar del error	0.70%

Interpretación de métricas:

- El RMSE de 11,749 botellas representa un error promedio del modelo de aproximadamente 2.1% respecto a la media histórica (563,286 botellas), lo que indica un desempeño aceptable.
- El MAE de 11,178 botellas es ligeramente inferior al RMSE, sugiriendo que los errores no contienen valores extremos significativos.
- El sesgo promedio de -2.04% indica que el modelo tiende a subestimar ligeramente las ventas, aunque con variabilidad baja (desv. est = 0.70%).

Detalle de errores por período de prueba:

Table 6. Pronósticos vs Valores reales (Periodo de prueba).

Mes	Real botellas	Pronóstico	Error botellas	Porcentaje Error
Jul-22	577315	586572	-9258	-1.60
Ago-22	562335	572411	-10077	-1.79
Sep-22	554753	564569	-9816	-1.77
Oct-22	549854	566765	-16911	-3.08
Nov-22	518752	535080	-16328	-3.15
Dic-22	538793	549474	-10681	-1.98
Ene-23	545640	560708	-15068	-2.76
Feb-23	585732	590019	-4287	-0.73
Mar-23	566885	577608	-10724	-1.89
Abr-23	511237	522686	-11449	-2.24
May-23	566369	572679	-6311	-1.11
Jun-23	547636	560860	-13224	-2.41

Análisis del patrón de errores:

- El modelo mostró consistencia en el sesgo negativo en 11 de 12 meses, subestimando las ventas.
- Los errores más grandes se observaron en octubre-noviembre ($\approx -3.1\%$) y enero (-2.76%), períodos con menor demanda observada.

- El mejor desempeño (menor error) se logró en febrero (-0.73%), indicando mejor captura del pico estacional.
- La distribución de errores es relativamente uniforme, sin patrones de heterocedasticidad. Aparentes.




Fig. 8. El gráfico de evaluación presenta un análisis comparativo entre los valores reales observados (línea azul oscura) y los pronósticos generados por el modelo (línea roja o anaranjada) durante el período de validación retrospectiva (julio 2022 a junio 2023). Esta superposición visual revela la precisión del modelo: donde ambas líneas coinciden, el pronóstico fue exacto; donde se separan, indica un error sistemático. El gráfico evidencia una tendencia consistente del modelo a subestimar las ventas, con una brecha promedio de -2.04%, siendo más pronunciada en períodos de baja demanda (octubre-noviembre) y mínima en picos de ventas (febrero). Debajo de la serie temporal, se grafica una representación de errores residentes, típicamente como barras que visualizan la magnitud y dirección de las desviaciones mes a mes. Las métricas numéricas superpuestas (RMSE=11,749, MAE=11,178) cuantifican el desempeño agregado. Esta visualización integral permite evaluar rápidamente si el modelo es adecuado para propósitos operativos e identificar períodos específicos que requieren ajuste estratégico.

3.4 Actividad 4

El modelo sobre la base de datos OpenFlights generó un grafo compuesto por 3214 aeropuertos y 36907 rutas de vuelo en total.

Durante el análisis de optimización de rutas, tomando como caso de estudio el trayecto entre el Aeropuerto Internacional de la Ciudad de México y el Aeropuerto Internacional John F. Kennedy, el algoritmo determinó que:

- **Trayecto con menos escalas:** La ruta más corta pertenece a un vuelo directo, partiendo específicamente del Aeropuerto Internacional de la Ciudad de México con destino al JFK.

- **Trayecto óptimo por distancia:** El algoritmo Dijkstra minimizó la distancia geográfica, resultando en un recorrido total de 3365.34 km en un solo vuelo directo

Se asimiló de forma práctica la diferencia entre la optimización topológica (menor número de aristas) y la optimización ponderada (menor peso/distancia) en un modelo de grafos. El uso de la fórmula de Haversine demostró cómo integrar cálculos geoespaciales en el análisis de redes para dotar de realismo a los pesos del grafo.

Respecto a las métricas globales, el análisis de conectividad reveló que la red no es fuertemente conexa ni débilmente conexa, lo que indica que existen aeropuertos o pequeñas redes regionales aisladas del sistema global de vuelos comerciales. Al extraer el componente principal de la red (que agrupa a 3,147 aeropuertos interconectados), se determinó que el diámetro del grafo es de 13 saltos; esto significa que, en el peor de los casos, cualquier aeropuerto dentro de esta macro-red está a un máximo de 13 escalas de distancia de cualquier otro.



Fig. 9. Mapa de trayectorias entre México y USA.

El grafo representa una visualización de la red de aeropuertos de OpenFlights. En color rojo y azul se destaca la ruta óptima calculada mediante el algoritmo Dijkstra sobre el modelo de la red.

El modelo actual asume que la ruta más corta equivale a la distancia más corta, ergo, en la logística real, la duración de un vuelo toma en cuenta valores externos (clima, corredores aéreos y tipo de aeronave), además el modelo no considera el tiempo de espera (escalas) en los aeropuertos intermedios.

3.5 Actividad 5

El grafo creado tuvo una cantidad de 7224 tripletas, y el dataframe con los datos limpios es de 2425 filas y 3 columnas. Debido a la enorme cantidad de universidades, se grafica una pequeña muestra, eligiéndose la ciudad y la cantidad máximas de nodos a mostrar. Sin embargo, para evitar la cantidad grande aristas en la imagen, al graficarse se toma una pequeña muestra del grafo que se desea mostrar. En este caso muestra 10 nodos en la ciudad de México. Con esta representación y adicionalmente que en el archivo ttl, se obtuvo una base de datos con ciudades, años de fundación y nombres de universidades, permitiendo realizar un conjunto de datos útil para análisis póstumos.




Fig. 10. Grafo de conocimiento generado con las universidades.

4 Conclusiones

Con esta tarea, al haberse concretado cada una de las actividades, se observaron las dificultades y particularidades que tiene cada tipo de dato, como el muestreo también puede ayudar al realizar alguna investigación o análisis. Adicionalmente, las características principales que se necesitan tomar en cuenta cuando se analizan datos del tipo geográfico y datos de series de tiempo. La actividad 3 da problemas con el método SARIMA para poder realizar proyecciones a largo plazo, y se utilizaron otros métodos paralelos al SARIMA de interpolación y extrapolación. El problema 1,2 conllevó

el análisis topológico de los datos en sus proyecciones de mapas, el quinto, intentar realizar visualizaciones simples a varias muestras de datos.

Referencias

1. Secretaría de Cultura. (s. f.). Sistema de Información Cultural: Espacios culturales. Gobierno de México. Recuperado el 20 de febrero de 2026, de (https://www.datos.gob.mx/dataset/sistema_informacion_cultural_espacios_culturales/resource/6b93540b-50e8-4d13-a11d-3fee4f080e9e)
2. scikit-learn developers. (s. f.). sklearn.metrics.pairwise.haversine_distances. Recuperado el 20 de febrero de 2026, (https://scikit-learn.org/stable/modules/generated/sklearn.metrics.pairwise.haversine_distances.html)
3. Géron, A. (2019). **Hands-on machine learning with scikit-learn, Keras, and TensorFlow** (2nd ed.). O'Reilly Media.