

mannwhitney wilcoxon

José Adrián Rodríguez González

16 de marzo 2026

1 Introducción

En esta ocasión se tratan 10 problemas de pruebas de Mann Whitney y Wilcoxon.

2 Rendimiento de dos algoritmos de clasificación

Dos algoritmos de clasificación (A y B) se evalúan sobre 25 particiones bootstrap del mismo dataset. Sin embargo, las métricas de F1-score no son normales (alta asimetría).

- Aplica la prueba U de Mann-Whitney para determinar si el algoritmo B supera al A.
- Calcula el tamaño del efecto (r o Cliff's delta).
- Interpreta qué implicaría la diferencia para un despliegue en tiempo real

2.1 Solución

Se aplica la prueba U de Mann-Whitney, se calcula de la siguiente forma

$$U_1 = n_1 n_2 + \frac{n_1(n_1 + 1)}{2} - R_1 \quad (1)$$

$$U_2 = n_1 n_2 + \frac{n_2(n_2 + 1)}{2} - R_2 \quad (2)$$

Las ecuaciones (1) y (2) se calculan ambos valores de U y adicionalmente, los valores R, son las sumas de los valores de los rangos que tiene cada distribución. El cálculo del estadístico U, se realiza de la siguiente manera

$$U = \min(U_1, U_2)$$

Adicionalmente, para poder medir la intensidad que se tiene de diferencia se utilizan los valores de r y de la δ de Cliff

$$r = Z/\sqrt{n}$$

$$\delta = \frac{\#(a > b) - \#(a < b)}{n_a n_b}$$

Dado a la pregunta, se proponen las siguientes hipótesis

$$H_0 : A \geq B$$

$$H_1 : A < B$$

La tabla muestra, que se acepta la hipótesis nula, y por lo tanto, no hay evidencia suficiente para decir que el algoritmo B haya mejorado el valor del F_1 score. La diferencia del valor de r es pequeño y por lo tanto la diferencia es muy pequeña, igual el valor del δ , también tiene un valor extremadamente pequeño. Reafirmando que inclusive las diferencias sean casi iguales. De igual manera, al observar el valor Z , demuestra que las diferencias son muy pequeñas indicando que estadísticamente, los valores de los algoritmos son muy pequeños. Para un despliegue en tiempo real, implica que si nos basamos en el F_1 score, es indistinto usar cualquiera de los algoritmos, posiblemente, otra variable a analizar sería observar si uno de los algoritmos es más rápido

estadístico	p-value	H0	Z	r	delta
334.000000	0.665260	True	0.417161	0.058996	0.068800

Table 1: Tabla de resultados de la primera pregunta

3 Diferencia en la actividad de sensores IoT

Se instalan sensores PIR de dos marcas distintas en una fábrica. Se registran 40 lecturas de activación diaria para cada marca, pero los datos están sobredispersos y no son gaussianos.

- Evalúa si una marca detecta más actividad que la otra.
- Construye un gráfico de distribuciones (violin o boxplot).
- Discute si la diferencia podría deberse a sensibilidad distinta o ruido ambiental

3.1 Solución

Para este caso, no se tiene sospecha específica de que sensor detecta más actividad, por lo tanto, lo dejamos en encontrar si existe evidencia suficiente para determinar alguna diferencia entre la medición de los sensores. Se proponen las siguientes hipótesis

$$H_0 : A = B$$

$$H_1 : A \neq B$$

estadístico	p-value	H0	Z
688.500000	0.285177	True	-1.072909

Table 2: Tabla de resultados

En la tabla 2, se observa que se acepta la hipótesis nula y por lo tanto, no existe evidencia suficiente para determinar que haya diferencia entre ambos sensores. A través de la imagen, podemos observar que si bien, el segundo sensores obtiene más mediciones, su centro de datos es muy parecido al del sensor A, y por esa razón, se indica que la diferencia no es completamente significativa para determinar si efectivamente un sensor mide más que otro.




Figure 1: Boxplot de mediciones de sensores

4 Salarios de científicos de datos en dos regiones

Una empresa compara salarios anuales de ingenieros de datos en dos regiones (Región Norte: $n=30$, Región Sur: $n=32$). La distribución es fuertemente asimétrica por bonos.

- Usa Mann-Whitney para comparar salarios.
- Evalúa la hipótesis de que la Región Sur paga más.
- Pregunta adicional: ¿qué tan robusto sería el test si existieran valores extremadamente atípicos?

4.1 Solución

Para este caso, se proponen las siguientes hipótesis

$$H_0 : A \geq B$$

$$H_1 : A < B$$

Siendo A la región del norte y B la región del sur. Acorde a los resultados

estadístico	p-value	H0	Z
383.000000	0.087027	True	-1.366333

Table 3: Tabla de resultados 3

obtenidos en el valor p, indican que se toma la hipótesis nula, por lo tanto, se dice que la región del norte paga más que la región del sur. Este test es más robusto ante outliers que el t student, debido a que los valores en los que se basa es en rangos, y por lo tanto, sí afecta, pero no de manera agresiva como el t student, debido a que este se basa en la comparación de medias.

5 Comparación de tiempos de ejecución entre dos GPUs

Se miden tiempos de inferencia (ms) de un mismo modelo en dos GPUs distintas (GPU-A y GPU-B) usando 50 ejecuciones cada una. Los tiempos muestran colas pesadas.

- Determina si GPU-B es significativamente más rápida.
- Calcula un tamaño del efecto no paramétrico.
- Concluye sobre la viabilidad de usar GPU-B en aplicaciones de baja latencia.

5.1 Solución

Se proponen las siguientes hipótesis

$$H_0 : A \geq B$$

$$H_1 : A < B$$

Siendo A la gpu A y B la gpu b. Por medio de la tabla 4, se acepta la hipótesis nula, demostrando que la GPU A. En la tabla 4, se demuestra que no hay evidencia suficiente para determinar que A sea más eficiente, sin embargo, por los valores de r, indican que existe un efecto moderado, adicionalmente de que el valor del δ , tiene un efecto moderado alto a su vez de que el valor Z indica que

estadístico	p-value	H0	Z	r	delta
1812.000000	0.999947	True	3.874327	0.387433	0.449600

Table 4: Tabla de resultados 4

si hay un diferencia alta. Por lo tanto, la prueba demuestra que no hay muestra suficiente, sin embargo, por la fuerza de la prueba, se encuentra que hay un claro indicio, de que la eficiencia de la GPU B, sea mayor que la del GPU A. Esto da indicios, de que la GPU B sea viable para tareas de baja latencia o de carga pesada

6 efectividad de dos técnicas de limpieza de dato

Dos métodos de limpieza (Método X y Método Y) procesan un dataset con mucho ruido. Después de entrenar un modelo, se obtiene el error MAE para 20 ejecuciones independientes de cada método. Los errores no son normales.

- ¿Qué método produce, en general, menor error?
- Evalúa la hipótesis con Mann–Whitney y reporta la mediana de cada grupo.
- Explica por qué elegir un test no paramétrico fue adecuado.

6.1 Solución

Se proponen las siguientes hipótesis

$$H_0 : A = B$$

$$H_1 : A \neq B$$

Como tal, no hay una sospecha de que algún modelo sea mejor, por lo tanto se procede a otra prueba, sin embargo, por medio de la prueba de Mann Whitney, se encuentra que el valor de p toa la hipótesis nula y por lo tanto, la diferencia de los valores de error MAE, no son lo suficientemente significativos para definir que algún modelo sea mejor o peor. Y por lo tanto, es necesario proceder a la segunda prueba, la diferencias de medianas y podemos observar que el que obtuvo una menor mediana es el modelo B, y por lo tanto, tomamos ese valor como el modelo que relativamente resultó siendo mejor. Escoger un test no paramétrico tiene sus ventajas, como no depender de normalidad, tampoco de varianzas iguales, funciona bien con datos de muestras pequeños y tiene mayor robustez antes valores atípicos

estadistico	p-value	H0	Z	median_A	median_B
250.000000	0.180577	True	1.352504	0.924350	0.718550

Table 5: Tabla de resultados del problema 5

7 Evaluación pre-post de un sistema de recomendación

Una plataforma actualiza su algoritmo de recomendaciones. Se comparan 25 usuarios, midiendo click-through rate (CTR) antes y después del cambio. La diferencia CTR no es normal.

- Aplica la prueba de Wilcoxon para comparar “antes” vs “después”.
- Determina si la actualización aumentó el CTR.
- Evalúa si existe un efecto significativo en usuarios de baja actividad.

7.1 Solución

Se proponen las siguientes hipótesis para la pregunta general

$$H_0 : \text{median}(A - B) = 0$$

$$H_1 : \text{median}(A - B) < 0$$

Siendo A, antes y B después. Estas mismas hipótesis se proponen para la tercera pregunta Se puede observar en la tabla 6, que se toma la hipótesis alternativa

estadistico	p-value	H0	Z
34.000000	0.000108	False	-3.457538

Table 6: Tabla de resultados problema 6

por lo tanto, implica que hay una diferencia significativa de que el algoritmo de recomendaciones haya mejorado la atención de los clientes e hizo que hubiera una mayor cantidad de clicks, por lo tanto, si aumento al cantidad de CTRs con la actualización, el valor de Z , afirma que es un valor de diferencia alto. Sin embargo, al observar y realizar esta prueba, pero solo al sector poblacional que presentase una baja actividad,(se toma aquellos individuos con menos del 25%). Se encuentra que no hay cambios significativos después de la actualización para este sector poblacional, en pocas palabras, las personas que tenían ya una baja actividad, siguen teniendo una menor actividad a pesar de la actualización

estadístico	p-value	H0	Z
4.000000	0.109375	True	-1.362770

Table 7: Tabla con la menor población

8 Error de localización de un dron antes y después de calibración

Un dron realiza 30 vuelos repetidos antes y después de una calibración avanzada del sistema IMU. Los errores absolutos tienen distribución sesgada.

- Usa Wilcoxon para determinar si la calibración mejoró la precisión.
- Evalúa gráficamente las diferencias (scatter + línea de identidad).
- Menciona posibles fuentes de variabilidad residual.

8.1 Solución

Se proponen las siguientes hipótesis

$$H_0 : \text{median}(A - B) = 0$$

$$H_1 : \text{median}(A - B) > 0$$

De tal manera que A es el antes de calibrarse y el B es el después de haberse calibrado y Por medio de la tabla 8, se observa que se toma la hipótesis alternativa,

estadístico	p-value	H0	Z
465.000000	9.31e-10	False	4.782139

Table 8: Tabla con los resultados del problema 7

implicando que el error anteriormente era mayor a comparación del error resultante después de haberse calibrado. Por medio de la figura 2, se puede observar la línea de referencia de los datos y demuestra que si existe una mejora, ya que todos los puntos están debajo de la línea de referencia. Visualmente confirma el valor de Z, que a pesar de que si hubo una mejoría, está no es tan extrema, ya que la mayoría de puntos se observa que están relativamente cerca de la línea. Algunas posibles fuentes de variabilidad, puede ser factores ambientales o de la transmisión de la señal que puedan afectar en la localización del dron.




Figure 2: Scatter plot de los errores

9 Comparación de consumo energético antes/después de optimizar código

Una aplicación edge-IA se ejecuta en el mismo microcontrolador antes y después de una refactorización. Se miden 20 ciclos de consumo energético (MJ) en ambas condiciones. Los datos presentan saltos discretos por modos de ahorro.

- Aplica Wilcoxon para comparar ambas condiciones.
- Indica si la refactorización realmente redujo el consumo.
- Calcula tamaño del efecto no paramétrico.

9.1 Solución

Para este problema, se proponen las siguientes hipótesis

$$H_0 : \text{median}(A - B) = 0$$

$$H_1 : \text{median}(A - B) > 0$$

Por medio de la tabla 9, se demuestra que por el valor tan pequeño de p, se toma la hipótesis alternativa, implicando que A tiene un mayor consumo energético implicando que el código optimizado, permite reducir el consumo energético, con el valor de r, demuestra que tiene un efecto grande. En pocas palabras, la refactorización si redujo el consumo

estadistico	p-value	H0	Z	r
190.000000	0.000064	False	3.173277	0.501739

Table 9: Resultados del problema 8

10 Calidad de imagen antes y después de aplicar un nuevo filtro

Un algoritmo de visión por computadora ajusta un filtro para mejorar nitidez. Para 18 imágenes, se compara la métrica SSIM antes y después del nuevo filtro. Los cambios no son normales.

- Determina con Wilcoxon si el filtro ofrece mejoras.
- Evalúa cuántas imágenes muestran mejora positiva vs negativa.
- Concluye sobre la robustez del filtro en distintos tipos de iluminación.

10.1 Solución

Para este problema se proponen las siguientes hipótesis

$$H_0 : \text{median}(A - B) = 0$$

$$H_1 : \text{median}(A - B) > 0$$

Por medio de la tabla 10, se demuestra que se toma la hipótesis alternativa, implicando que el nuevo filtro mejoró la métrica SSIM. La cantidad de imágenes con una mejoría positiva fueron 15 mientras que las negativa fue de 2 por lo tanto, un 83.33% de las imágenes mejoraron al haberse aplicado el filtro. Esto demuestra, que este filtro al haberse aplicado en distintas de diferentes tipos de imágenes con diferentes grados de luminancia, puede mejorar la nitidez de la imagen

estadístico	p-value	H0	Z	Buena	mala	igual
4.000000	0.000300	False	-3.549354	15	2	1

Table 10: Resultados de la tabla 9

11 Latencia de una API antes vs después de migrar infraestructura

Un servicio migra su backend a una arquitectura serverless. Se recogen 40 pares de mediciones de latencia para llamadas equivalentes antes/después. Las diferencias tienen clara asimetría.

- Aplica Wilcoxon para evaluar la mejora en latencia.
- Reporta la magnitud de la reducción (mediana de diferencias).
- Discute posibles causas de la variabilidad residual.

11.1 Solución

Para este problema las siguientes hipótesis

$$H_0 : \text{median}(A - B) = 0$$

$$H_1 : \text{median}(A - B) > 0$$

Siendo A el backend antiguo y el B el servicio backend serverless Por medio de los resultados obtenidos en la tabla 11, se observa que se toma la hipótesis alternativa, implicando que existe una mejoría con el cambio de backend a un servicio serverless. Por medio de las medianas se observa que hay una mejoría significativa con el servicio serverless, y mediante la mediana de diferencias, se observa que hay una diferencia de 38 milisegundos, resultando en una posible buena mejoría. Puede existir alguna variabilidad residual debido a optimizaciones que haga el sistema, cold starts de algunos servidores serverless, también que tan buena es la red del internet, la cantidad de solicitudes o el ruido del sistema de medición, a su vez que parte del balanceador de cargas del servicio de nube

estadistico	p-value	H0	Z	median_A	median_B	median_d
820.000000	9.09e-13	False	5.510932	170.275000	132.535000	38.115

Table 11: Tabla 10 de resultados

12 Conclusión

Por medio de los anterior problemas, se puso en práctica las pruebas no paramétricas, encontrando diversas aplicaciones en diversos sectores