



Universidad de Guanajuato

Materia: Análisis de estados

Carrera: Licenciatura en Ingeniería de Datos e Inteligencia Artificial

Tarea 5 de Chi cuadrada

Alumno: José Adrián Rodríguez González

NUA: 148661

Profesor: Dr. Felipe de Jesús Trujillo

25 de marzo de 2026

Índice general

1. Introducción	2
2. Problemas	3
2.1. Problema 1: Relación entre tipo de error del modelo y clase predicha (Independencia)	3
2.1.1. Razón del problema	3
2.1.2. Soluciones	3
2.2. Problema 2: Detección de sesgo en un modelo de recomendación (Independencia)	4
2.2.1. Problema	4
2.2.2. Solución	4
2.3. Clasificación de fallas en sensores IoT por tipo de dispositivo	5
2.3.1. Problema	5
2.3.2. Solución	5
2.4. Preferencia de arquitectura de red neuronal por empresa	6
2.4.1. Problema	6
2.4.2. Solución	6
2.5. ¿Distribuyen los errores de un modelo según lo esperado?	7
2.5.1. Problema	7
2.5.2. Solución	7
2.6. Verificación de distribución de tráfico por hora en una API	8
2.6.1. Problema	8
2.6.2. Solución	8
2.7. Relación entre tipo de algoritmo de clustering y estabilidad de grupos .	9
2.7.1. Problema	9
2.7.2. Solución	9
2.8. Análisis de sentimientos por plataforma	10
2.8.1. Problema	10
2.8.2. Solución	10
2.9. Existen diferencias en aprobaciones de crédito por región?	11
2.9.1. Problema	11
2.9.2. Solución	11
2.10. Validación de un modelo generativo categórico	12
2.10.1. Problema	12
2.10.2. Solución	12

Capítulo 1

Introducción

En esta tarea se realizaron 10 ejercicios de la prueba de Chi cuadrada, tanto en pruebas de muestras independientes como en ajuste de bondad. Para ello, se utilizó el software de Python y la librería de scipy que contiene funciones estadísticas y que ha ayudado a lo largo de esta serie de tareas para la realización de pruebas como la t student, wilcoxon, y mann whitney.

Capítulo 2

Problemas

2.1. Problema 1: Relación entre tipo de error del modelo y clase predicha (Independencia)

2.1.1. Razón del problema

Un modelo de clasificación multicategoría genera una matriz con la frecuencia de errores por clase (falsos positivos y falsos negativos por categoría).

- Construye una tabla de contingencia entre tipo de error (FP/FN) y clase predicha (A, B, C).
- Aplica una prueba chi-cuadrada de independencia.
- Evalúa si el tipo de error depende de la clase.
- Discute implicaciones para el bias del modelo.

2.1.2. Soluciones

En la tabla 2.1, se observa la tabla de contingencia para cada clase y para cada tipo de error, se le aplicó una prueba de chi cuadrada, no sin antes proponer lo siguiente.

$$H_0 : P(Y = j|X = i) = P(Y) \forall i, j$$

$$H_1 : \exists P(Y = j|X = i) \neq P(Y)$$

Es decir, se busca probar si el tipo de error es dependiente de las clases. Cuando se aplica la prueba de chi cuadrado, teniendo primariamente la frecuencia observada como cada muestra O_{ij} que se tenga en la tabla y la E_{ij} , como el $E_{ij} = \frac{\# \text{Total por fila}_i \cdot \text{Total por columna}_j}{n}$. Siendo finalmente el estadístico $\chi^2_{critico} = \sum \frac{O-E}{n}$. Los resultados obtenidos se pueden visualizar en la tabla 2.2, al tener 2 grados de libertad y contar un valor p menor que el 0,05, implica que tomamos la hipótesis alternativa, implicando que no hay muestra suficiente para determinar que el tipo de error sea independiente de la clase. Esto podría decirnos que acorde a lo datos, el modelo presenta un sesgo hacia una cierta clase, ya que no hay una proporción similar de tipo de error por clase.

error type /predicted class	A	B	C
FN	106	113	45
FP	118	87	131

Cuadro 2.1: Tabla de contingencia de las clases y su tipo de error

chi	p-value	dof
37.952095	5.738e-09	2

Cuadro 2.2: Tabla de resultados

2.2. Problema 2: Detección de sesgo en un modelo de recomendación (Independencia)

2.2.1. Problema

Una app de streaming registra si un usuario acepta o rechaza una recomendación según su grupo de edad: 18–25, 26–35, 36–50.

- Evalúa si la aceptación depende del grupo de edad.
- Incluye tamaño del efecto (V de Cramer).
- Determina si existe sesgo algorítmico.

2.2.2. Solución

Se realiza una prueba de hipótesis de independencia de la siguiente manera

$$H_0 : P(Y = j|X = i) = P(Y)\forall ij$$

$$H_1 : \exists P(Y = j|X = i) \neq P(Y)$$

Esto implica que se busca demostrar que si hay dependencia del rango de edades con respecto al grado de aceptación de una aplicación, según los resultados encontrados en la tabla 2.2, se muestra que el valor de p es menor a 0,05, por lo tanto, implica que si existe una dependencia entre las muestras, por lo tanto implica, que el nivel de aceptación si es dependiente a los rangos de edad. Se pueden determinar el grado de las asociación por medio de la V de crammer que se calcula de la siguiente manera

$$V = \sqrt{\frac{\chi^2/n}{\min((k-1), (r-1))}}$$

Siendo n el total de observaciones, k es al cantidad de columnas y r el número de filas, Adicionalmente del valor del estadístico, el χ^2 . El resultado se puede interpretar como una asociación moderada con el valor de 0,3, por lo tanto, se puede concluir que si existe una cierta relación en el rango de edad con la aceptación, implicando que existe un sesgo algorítmico.

chi	p-value	dof	Crammer
13.565797	0.001133	2	0.130220

Cuadro 2.3: Tabla de resultados

2.3. Clasificación de fallas en sensores IoT por tipo de dispositivo

2.3.1. Problema

En una red IoT industrial se registran fallas de 3 tipos:

- Falla eléctrica
- Falla de comunicación
- Falla ambiental
- Los dispositivos pertenecen a tres familias:
- Sensor T°, Sensor Vibración, Sensor Humedad.

Realizar:

- Evaluar si el tipo de falla es independiente del tipo de sensor.
- Interpretar los resultados para mantenimiento predictivo.

2.3.2. Solución

Para este problema se proponen la siguientes hipótesis

$$H_0 : P(Y = j|X = i) = P(Y) \forall ij$$

$$H_1 : \exists P(Y = j|X = i) \neq P(Y)$$

Se busca demostrar la dependencia entre las muestras Por medio de la tabla 2.4, se

chi	p-value	dof	crammer
52.380475	1.148e-10	4	0.482496

Cuadro 2.4: Tabla de resultados

encuentra que el valor de p es mucho menor a 0,05 implicando que en realidad, si existe una cierta dependencia entre los valores de los sensores y los tipos de fallas, si observamos los valores de la tabla 2.5, tiene sentido que la prueba demuestra que si exista una cierta asociación, por que por ejemplo, se observa que los sensores de humedad detectan más fallas ambientales, y tiene sentido, los problemas ambientales en su mayoría surgen por problemas o de temperatura o de humedad, pero principalmente

de humedad, ya que en una central eléctrica, resulta muy perjudicial fallas por humedad, pudiendo corroer algún cable. Mientras tanto que por la parte de temperatura, se asocia más a fallos eléctricos y esto, también tiene sentido. La mayoría de los fallos eléctricos se engrosan cuando la temperatura es mayor, ya que pudo haber sido un corto circuito en alguna zona y provoca calor, o adicionalmente, también el desgaste de una aislante, cuando empieza una aislante de cable a desgastarse se calienta demás y quema el material aislante, u en otro caso, cuando un transformador falla, la temperatura se eleva debido a que el enfriador del transformador ya no es tan eficiente y no se cambió el aceite. Por otra parte, los problemas de comunicación son mayormente detectados por sensores de vibración, igual también tiene sentido, ya que si un sensor está calibrado para detectar cierta frecuencia de vibraciones, muchos sistemas de comunicación inalámbrica pueden fallar por interferencia o inclusive, cuando no existe la comunicación, no hay vibraciones en el medio, y puede ser algo que también el sensor detecte. La intensidad de Crammer demuestra que es casi fuerte la asociación y por lo comentado, logra tener un cierto sentido la dependencia y el fallo del sensor.

sensor type/failure type	Ambiental	Comunicacion	Electrica
Humedad	70	35	38
Temp	53	37	79
Vibracion	31	71	36

Cuadro 2.5: Tabla de contingencia de los sensores y el tipo de falla que detectan

2.4. Preferencia de arquitectura de red neuronal por empresa

2.4.1. Problema

Tres empresas evalúan tres arquitecturas de deep learning: CNN, Transformer, GNN, y reportan cuántos proyectos usan cada una.

- Determina si las distribuciones de preferencia son homogéneas entre empresas.
- Identifica qué arquitectura muestra mayor variación entre organizaciones.

2.4.2. Solución

Las hipótesis que se proponen son las siguientes

$$H_0 : P(Y = j|X = i) = P(Y = j|X = i') \forall j$$

$$H_1 : \exists P(Y = j|X = i) \neq P(Y = j|X = i')$$

Con eso, la alternativa implica que hay independencia en los datos y acorde a lo observado en la tabla de resultados, se observa que el valor de p es más bajo que el 0,05, por lo tanto, implica que las distribuciones de aceptación entre empresas, de ciertos modelos deep learning en sus proyectos, es independiente, en la tabla. Se observa que

para la empresa A, se usa y se acepta más el uso de las redes convolucionales, mientras que para la empresa B, aceptan más el uso de redes de transformers, mientras que la C, acepta más el uso de modelo de grafos. Además, se puede ver que en la empresa A, se rechaza el uso de grafos, mientras que en la empresa B, se rechaza más el uso de convolucionales. Mientras que la empresa C, rechaza el uso de modelos de transformadores. Si analizamos por arquitecturas, podemos observar que aquel que tiene más variación es el modelo de GNN, esto debido a que hay una empresa que lo acepta más.

chi	p-value	dof	crammer
32.650309	0.000001	4	0.394307

Cuadro 2.6: Tabla de resultados

architecture company	CNN	GNN	Transformer
EmpresaA	2.019830	-1.977206	-0.337452
EmpresaB	-1.704460	-1.163259	2.442215
EmpresaC	-0.240586	3.107145	-2.147645

Cuadro 2.7: Tabla de varianzas por modelo por empresa

2.5. ¿Distribuyen los errores de un modelo según lo esperado?

2.5.1. Problema

Se espera que los tipos de error (FP, FN, TP, TN) para un modelo binario sigan una proporción teórica dada por una simulación previa.

- Contrasta las frecuencias reales con las teóricas mediante una chi-cuadrada de bondad de ajuste.
- Discute si el modelo funciona según lo simulado.

2.5.2. Solución

Para este problema se proponen las siguientes hipótesis

$$H_0 : P(X = i) = p_i$$

$$H_1 : P(X = i) \neq p_i$$

Según los resultados mostrados en la tabla 2.8, se acepta la hipótesis nula ya que el valor de p es mayor a 0,05, implicando que la distribución observada es muy parecida a la esperada, por lo tanto, el modelo funciona según lo esperado

chi	p-value
6.4689	0.0908

Cuadro 2.8: Tabla de resultados

2.6. Verificación de distribución de tráfico por hora en una API

2.6.1. Problema

Una API recibe peticiones por hora. La empresa propone que el tráfico se ajusta a una distribución uniforme durante el día. Tarea:

- Construye frecuencias por hora (24 categorías).
- Aplica una prueba de bondad de ajuste a uniforme.
- Evalúa si la hipótesis de uniformidad es plausible.

2.6.2. Solución

Se proponen las siguientes hipótesis

$$H_0 : P(X = i) = p_i$$

$$H_1 : P(X = i) \neq p_i$$

Es decir, la prueba de alternativa, implica que la distribución del tráfico de la API no sigue una distribución uniforme

chi	p-value
70.484846799742	1.023331e-6

Cuadro 2.9: Tabla de resultados

Por los resultados obtenidos en la tabla 2.9, se observa que se toma la hipótesis alternativa debido a que es menor a 0,05, implicando que la distribución observa no sigue una distribución. Esto se puede visualizar con una gráfica de frecuencias y se observa que en la figura 2.1, los datos muestran un peso mayor hacia la derecha, implicando que hay más consulta la API de las 9 hasta las 19 horas, aproximadamente, es decir, en un horario laboral, implicando que la API no necesariamente presenta datos con una distribución uniforme




Figura 2.1: Frecuencias por hora

2.7. Relación entre tipo de algoritmo de clustering y estabilidad de grupos

2.7.1. Problema

Se evalúan dos algoritmos de clustering: K-means y DBSCAN. Cada uno produce etiquetas que se clasifican como estables o inestables (según medidas de Silhouette en datos perturbados).

- Evalúa si la estabilidad depende del algoritmo.
- Incluye análisis de residuales para interpretar qué algoritmo genera más inestabilidad.

2.7.2. Solución

Se proponen las siguientes hipótesis

$$H_0 : P(Y = j|X = i) = P(Y) \forall i, j$$

$$H_1 : \exists P(Y = j|X = i) \neq P(Y)$$

Es decir, con la hipótesis alternativa se busca demostrar si la estabilidad es dependiente al algoritmo. Según la tabla 2.10, demuestra que el valor p es muy bajo al grado que

toma la hipótesis alterna como verdadera, e indica, que la distribución de estabilidad es dependiente del algoritmo, y con esa conclusión, podemos decir que el algoritmo más inestable es DBSCAN, debido a que en la estabilidad, muestra valores residuales negativos y en la inestabilidad positivos, implicando que es inestable este algoritmo

chi	p-value	dof
15.337964	0.000090	1

Cuadro 2.10: Tabla de resultados

stability algorithm	Estable	Inestable
DBSCAN	-1.693762	2.266541
KMeans	1.693762	-2.266541

Cuadro 2.11: Calculo de valores residuales

2.8. Análisis de sentimientos por plataforma

2.8.1. Problema

Se recolectan opiniones positivas, neutras y negativas de un mismo producto en tres plataformas: Twitter, Reddit y TikTok.

- Contrasta si las distribuciones de sentimiento son homogéneas entre plataformas.
- Determina qué plataforma difiere más usando análisis post-hoc de los residuales.

2.8.2. Solución

Se proponen las siguientes hipótesis

$$H_0 : P(Y = j|X = i) = P(Y = j|X = i') \forall j$$

$$H_1 : \exists P(Y = j|X = i) \neq P(Y = j|X = i')$$

Implicando, que con la hipótesis alternativa, las distribuciones entre red social, son independientes, y por medio de los resultados presentados en la tabla 2.13, se observa que valor p rechaza la hipótesis nula implicando que al menos una distribución muestra un comportamiento diferente. Y podemos observar que la plataforma con más diferencia de sentimientos es tiktok con valores más positivos, mostrando que la cantidad de comentarios positivos es mayor que negativos. Curiosamente, en la red de twitter se demuestra que hay comentarios negativos, y que en reddit tienden más a un tinte neutro. Sin embargo tiktok, se muestra como una plataforma demasiado positiva con el producto.

chi	p-value	dof
22.034664	0.000197	4

Cuadro 2.12: Tabla de resultados

sentiment platform	Negativo	Neutro	Positivo
Reddit	0.552538	1.451840	-1.569690
TikTok	-2.191806	-1.054987	2.604233
Twitter	1.731223	-0.326347	-1.164012

Cuadro 2.13: Análisis post hoc

2.9. Existen diferencias en aprobaciones de crédito por región?

2.9.1. Problema

Una entidad financiera registra decisiones de aprobación (“Sí”/“No”) en 4 regiones del país.

- Evalúa si la aprobación es independiente de la región.
- Calcula V de Cramer.
- Discute implicaciones éticas y de equidad algorítmica.

2.9.2. Solución

Para este problema, se sugieren las siguientes hipótesis

$$H_0 : P(Y = j|X = i) = P(Y) \forall i, j$$

$$H_1 : \exists P(Y = j|X = i) \neq P(Y)$$

ES decir, la hipótesis alternativa determinar si existe dependencia entre los valores. Por los resultados obtenidos en la tabla 2.14, se encuentra que el valor de p es mayor que 0,05, implicando que se acepta la hipótesis nula, por lo tanto, las distribuciones de aprobación de crédito si son independientes, implicando que ha de existir un sesgo relevante por región, y eso se puede observar en la V de Crammer, ya que en general, muestra valores casi 0. Esto implica que no hay una equidad en región implicando que algunas regiones están *quemadas* para sacar crédito, pero, esto solo si tomamos en cuenta estas dos variables, pueden haber otras que den una causalidad y no solo la correlación visible, con respecto a porque ciertas regiones se les asigna más crédito que a otras.

chi	p-value	dof	Crammer
5.173196	0.159545	3	0.065658

Cuadro 2.14: Resultados del problema 9

2.10. Validación de un modelo generativo categórico

2.10.1. Problema

Un modelo generativo produce valores categóricos entre 5 clases. La distribución real conocida es:

- Clase A: 0.25
- Clase B: 0.20
- Clase C: 0.18
- Clase D: 0.22
- Clase E: 0.15
- Evalúa si la distribución generada coincide con la real esperada.
- Usa chi-cuadrada de bondad de ajuste y discute discrepancias.

2.10.2. Solución

$$H_0 : P(X = i) = p_i$$

$$H_1 : P(X = i) \neq p_i$$

Se proponen las siguientes hipótesis, esto quiere decir que la hipótesis nula busca definir si ambas distribuciones, (esperada y observada) son iguales. Con los resultados de la tabla ??, se demuestra que el valor p es menor que 0,05, implicando que se rechaza la hipótesis nula y se toma la alternativa, implicando que la distribución observada si es diferente a la esperada, incidiendo que los datos generados por el modelo generativo, son diferentes y no está haciendo inferencia de manera correcta, por lo tanto, es necesario ajustar el modelo u observar alguna falla posible que tenga el modelo

chi	p-value
9.60	0.047

Cuadro 2.15: Tabla de resultados