

PRACTICA 1: DE DATOS ESTRUCTURADOS, SEMI-ESTRUCTURADOS Y NO ESTRUCTURADOS

Análisis de datos

Universidad de Guanajuato
División de Ingenierías Campus Irapuato-Salamanca

Barroso Solorzano Jorge Antonio
Illescas Flores Marco Uriel
Rodríguez González José Adrián
Valdés Velazquez Héctor Emilio

14 de febrero de 2026

Datos estructurados y no estructurados

Jorge Barroso¹, Marco Illescas¹, Adrián Rodríguez¹, Valdés Velazquez¹

¹Universidad de Guanajuato, División de Ingenierías, Campus Irapuato-Salamanca, Guanajuato, México.

Abstract. Este reporte técnico integra el desarrollo de cuatro actividades orientadas al procesamiento y análisis de datos en diversos formatos de datos como; estructurados, semiestructurados y no estructurados, utilizando tecnologías que facilitan su análisis. Con el fin de abordar diversas tareas como el observar las tendencias musicales, calidad del aire, análisis de texto en Wikipedia y el boletín oficial del estado. Los resultados demuestran la capacidad de transformar datos crudos provenientes de fuentes comerciales, ambientales, web y legales en información analítica estructurada.

Palabras clave: Conjunto de datos, análisis de datos, series de tiempo, datos no estructurados.

1 Introducción

En el día a día de la ciencia de datos, existen diversas fuentes de información y maneras en las que se pueden estructurar los datos y es menester comprender el manejo de cada tipo de dato. El objetivo de esta práctica es aplicar técnicas elementales de procesamiento de datos mediante cuatro enfoques complementarios. El primero consiste en una base de datos de SQL comercial de música, tendencias en los géneros y gustos musicales. La segunda tarea se profundiza en el análisis de series temporales para el monitoreo de la calidad del aire, empleando modelos ARIMA para la predicción de tendencias. La tercera fase de esta práctica se centra en el web scrapping de un sitio de Wikipedia, utilizando tanto la base del DOM en la estructura de un sitio web y técnicas avanzadas de procesamiento de lenguaje natural (PLN) como el Name Entity Recognition para la extracción de conocimiento desde fuentes web. Finalmente, se aborda la gestión de documentos legales en formato XML, utilizando XPath para la extracción jerárquica de información y llamadas de APIs para la obtención de datos. En conjunto, estas actividades proporcionan una visión integral del ciclo de vida del dato, desde su adquisición y limpieza hasta su análisis y visualización.

2 Metodología

2.1 Actividad 1: Análisis exploratorio con Pandas + SQLite

Centrada en el análisis exploratorio de datos, la actividad se desarrolló mediante la integración de SQL y Python, acompañado de un flujo de trabajo dividido en cuatro fases principales: conexión, extracción, procesamiento y visualización para una base de datos que representa el historial operativo de una tienda de medios digitales (como iTunes o Spotify), conteniendo datos relacionados con Artistas, Álbumes, Canciones, Clientes, Empleados y Facturas.

El análisis se llevó a cabo utilizando el lenguaje de programación y entorno Python. Se emplearon las librerías “sqlite3” para la gestión de la base de datos, “pandas” para la manipulación de estructuras de datos tabulares y “seaborn” más “matplotlib.pyplot” para la generación de gráficos de tipo estadísticos. El procedimiento a seguir fue el siguiente:

Conexión y Gestión de Rutas

Se estableció una conexión con la base de datos de tipo relacional “Chinook_Sqlite”. Para garantizar la portabilidad del código y evitar errores de lectura en diferentes sistemas operativos, se utilizó la librería “os” y su método general para construir la ruta absoluta del archivo de manera dinámica, posteriormente se implementó una validación previa que asegura la disponibilidad del archivo antes de intentar la conexión.

Extracción de Datos (consultas SQL)

Se diseñaron tres consultas SQL para extraer la información necesitada directamente desde el motor de la base de datos:

- Ventas por País: Se utilizó una consulta de agregación y agrupación sobre la tabla “Invoice” para obtener el volumen financiero por región.
- Análisis de Artistas: Se implementó una consulta con múltiples uniones, conectando las tablas “Artist”, “Album”, “Track” y “PlaylistTrack” para obtener la frecuencia de aparición de cada artista en las listas de reproducción.
- Series Temporales: Se extrajo la evolución temporal de las ventas formateando la fecha de facturación a un formato “Año-Mes”, permitiendo agrupar los ingresos mensualmente.

Procesamiento

Los resultados obtenidos de las consultas se cargaron directamente en DataFrames (df) de Pandas. Para el análisis visual (mapa de calor), se realizó una transformación de los datos para reestructurar el df, colocando los países como índice y los años como columnas, rellenando valores nulos con 0 para mantener la integridad de la matriz.

Visualización de la información

Los resultados se observaron tras la generación de tres grafos realizados por seaborn, siendo estos:

- Mapa de calor
- Gráfico de barras
- Gráfico de líneas

2.2 Actividad 2: Análisis de series temporales

Para esta actividad se utilizó el conjunto de datos **AirQualityUCI**, el cual contiene respuestas de sensores de calidad del aire en una ciudad italiana. El proceso se dividió en tres fases críticas:

1. **Limpieza y Preprocesamiento:** Se realizó la carga de datos asegurando el formato `datetime`. Debido a la naturaleza de las series temporales, se aplicó una **interpolación lineal basada en el tiempo** para cubrir valores faltantes, manteniendo la continuidad de la tendencia. Posteriormente, se aplicó el método de **Rango Intercuartílico (IQR) modificado** para tratar valores atípicos que pudieran sesgar el modelo.
2. **Análisis de Descomposición:** Se utilizó la función `seasonal_decompose` para separar la serie en sus componentes de **tendencia** (dirección a largo plazo), **estacionalidad** (patrones cíclicos) y **residuos** (ruido aleatorio).
3. **Modelado Estadístico:** Se implementó un modelo **ARIMA** (AutoRegressive Integrated Moving Average). Se seleccionaron los parámetros (p, d, q) tras analizar la estacionariedad de la serie, permitiendo generar proyecciones futuras.

2.3 Actividad 3: Scraping de HTML con BeautifulSoup + Análisis Semántico

El objetivo de esta actividad fue extraer información estructurada desde una página web y enriquecerla mediante técnicas de Procesamiento de Lenguaje Natural (PLN). Se trabajó con un artículo de Wikipedia como fuente de datos no estructurados, el cual fue procesado mediante herramientas del ecosistema Python

Obtención del contenido HTML

Se realizó una solicitud HTTP para descargar el documento HTML completo del artículo seleccionado. Para garantizar una respuesta válida del servidor, se configuró un encabezado que simula la navegación desde un navegador web convencional.

Análisis de la estructura del documento

El contenido descargado fue procesado utilizando un analizador sintáctico que permite recorrer el árbol DOM del documento. A partir de esta estructura se extrajeron los siguientes elementos:

- Título principal del artículo.
- Encabezados de sección (niveles h2 y h3).
- Párrafos informativos.
- Tablas relevantes con formato enciclopédico.

Esta etapa permitió transformar un documento diseñado para visualización humana en un conjunto de datos organizados.

Limpieza y normalización del texto

EL texto extraído contenía ruido típico del formato HTML, como saltos de línea innecesarios y espacios redundantes. Se aplicaron procesos de limpieza para obtener contenido textual continuo, legible y apto para análisis computacional.

Procesamiento de Lenguaje Natural

Se empleó un modelo lingüístico en español para enriquecer los datos mediante:

- Reconocimiento de entidades nombradas (NER): identificación automática de conceptos relevantes como tecnologías, organizaciones, fechas y términos técnicos.
- Análisis por párrafo: cada fragmento textual fue procesado individualmente para detectar las entidades presentes, permitiendo inferir su temática dominante.

Esta fase añadió una capa semántica a los datos previamente estructurados.

Generación de salida estructurada

Finalmente, la información fue organizada en un archivo JSON que integra los metadatos del artículo, las secciones detectadas, texto limpio, entidades identificadas y la relación entre párrafos y categorías semánticas.

El resultado es un dataset reutilizable para análisis posteriores o integración en sistemas de información.

2.4 Actividad 4: Procesamiento XML con lxml para documentos legales

Para esta sección se trabajó, con el Boletín Oficial del Estado, (BOE), es el homólogo español al diario oficial de la nación, donde se puede consultar promulgaciones, normativas, leyes, acuerdos y anuncios de la federación. Para poder consultar la información se hace uso de la API oficial que ellos proporcionan.

Paso 1, la búsqueda de la información

Se consulta la información del BOE por medio de una petición GET y se descarga la respuesta en formato XML. Se desarrolla una función denominada *API_call*, que recibe el url de la página web, el modo de petición y las cabeceras. En este caso, se recomienda utilizar una cabecera en la que fuerza la petición del tipo de archivo XML. Posee un manejador de error por si en algún caso, la respuesta de la petición fuese diferente de 200. Para este ejemplo, se utilizó el boletín del día 2 de febrero del 2026

Paso 2, la carga del documento y exploración de los datos.

Para este paso se necesita cargar el documento XML, mediante la función *load_documents*, permite cargar el objeto etree que posee la estructura del archivo XML. Se necesita únicamente la dirección del archivo y regresa este objeto de tipo árbol. Gracias a

la obtención de la estructura, se puede realizar una exploración con mayor cautela. El archivo principalmente consta de las siguientes partes

- Metadatos
- Diario
 - Sumario diario
 - Sección
 - Departamento
 - Epígrafe
 - Ítem

Con esta estructura general, se extraen primeramente los metadatos, que contiene la información del nombre de la publicación y la fecha de publicación. Subsecuentemente, se extraen los datos previamente mencionados en la lista de elementos y son almacenados en una lista de diccionarios para poderlos manejar de una manera tabular, particularmente utilizando la librería de pandas. La función *explore_file*, realiza esta tarea de recolección de información y de la transformación de formato XML a un formato tabular. La función retorna un `pandas.DataFrame`.

Paso 3, análisis de datos

Para esta sección se busca sacar las frecuencias absolutas y relativas de los tipos de mandatos, acuerdos o resoluciones que llegaron a hacerse en ese día. Para esa tarea, se define una lista de categorías de tipos de legislaciones que se pueden hacer.

- Ley
- Real Decreto
- Decreto
- Orden
- Resolución
- Acuerdo
- Anuncio
- Enmienda
- Convenio
- Tratado

Dado que, bajo el marco de la ley español, existen más tipos de mandatos, se utilizaron principalmente estos debido a la exploración del documento. Mediante una expresión regular, buscamos en la columna de título, cada uno de los mandatos dentro del nombre de cada título. Sin embargo, para este ejemplo, existe el caso particular que dentro de la sección hay nombres de entidades federativas españolas, pero todas las muestras con esta característica en común forman parte de la sección de justicia. Así que se toma la categoría de *justicia*, aquellos acuerdos del marco jurisprudencial. Finalmente, si alguna muestra no forma parte de ninguna de las categorías previamente mencionadas, se le cataloga con el marco de *otro*. La función retorna los conteos como las frecuencias relativas por categoría. Esto se calcula dividiendo el conteo de una categoría entre el total de muestras.

$$frecuencia\ relativa = \frac{Conteo\ por\ categoria}{total}$$


Paso 4, Visualización de los datos

Con lo obtenido del análisis de los datos, se presentan dos funciones que una gráfica una gráfica de barras y otra, un gráfico de pastel mostrando las proporciones. Ambas funciones *grafica_barras* y *graficar_pastel*, reciben un *pandas.Series* y el nombre/ubicación de la imagen.

3 Resultados y Discusión de resultados

3.1 Resultados Actividad 1

Las consultas realizadas presentaron una dominación referente a la música y economía:



- Distribución de Ventas por País y Año: El primer análisis, siendo este referente a las ventas totales, mostró una predominancia del mercado norteamericano. Como se observa en los datos tabulares, USA lidera con un total de 523.06 unidades monetarias, seguido por Canadá con 303.96, en tercer lugar, aparece Europa, más concretamente Francia con 195.10 y seguida por Brasil que cuenta con 190.10, indicativo de una buena presencia en Sudamérica. Para comprender este comportamiento, se analizó un mapa de calor que cruza la ubicación geográfica con el año fiscal:

El mapa de calor permite observar que, aunque USA mantiene un volumen alto constante, existen mercados emergentes como República Checa e India que, aunque tiene totales menores (90.24 y 75.26 respectivamente), muestran actividad constante. De igual manera, se observa que la mayoría de los países europeos (Alemania, Reino Unido, Portugal) mantienen un nivel de ventas medios, sin picos tan altos como los manejados por el mercado americano.

Popularidad de Artistas en las listas de reproducción: Se analizó la frecuencia con la que las canciones de los artistas aparecen en las listas de reproducción creadas por los usuarios o el sistema. Se puede teorizar que este indicador tuvo su creación para entender las preferencias de consumo musical dentro de la plataforma.




Ilustración 1 - Top 10 artistas con más Reproducciones

Los resultados observados muestran una tendencia clara hacia el Rock y Heavy Metal clásico, siendo “Iron Maiden” el artista con mayor frecuencia por un margen significativo al tener 516 apariciones en las listas de reproducción, siguiendo “U2” con 333 y “Metallica” con 296. El resto del "Top 10" incluye a bandas como “Led Zeppelin”, “Deep Purple” y “Pearl Jam”.

Es notable la ausencia de artistas de géneros como Pop moderno o música latina en el top 10, lo que sugiere que la base de datos Chinook tiene un catálogo o una base de usuarios fuertemente inclinada hacia el rock clásico de las décadas de 1980 y 1990.

- **Evolución Mensual de las Ventas:** Se evaluó el comportamiento financiero de la tienda a lo largo de los años, desde enero de 2021 hasta diciembre de 2025, para identificar estacionalidad o tendencias de crecimiento.




Ilustración 2 - Tendencias de Ventas Mensuales

La serie temporal muestra el comportamiento con cambios constantes, reflejando que, durante gran parte del 2021, las ventas se mantuvieron estables en torno a 37.62; se observan incrementos puntuales, como en enero 2022 (52.62) y abril 2023 (51.62). Estos picos podrían estar asociados a campañas promocionales o lanzamientos de álbumes importantes.

Por el lado contrario, noviembre 2023 (23.76) o febrero 2025 (27.72) registran caídas considerables de ventas, indicando problemas operativos, falta de inventario o estacionalidad negativa en esos periodos específicos.

Se aprecia que no existe un crecimiento exponencial ni un declive fatal, hablando de un negocio con una base de ingresos recurrente con pequeñas fluctuaciones mensuales.

3.2 Resultados Actividad 2

A. Descomposición Estacional

En la gráfica de descomposición generada (ver Ilustración X), se observa una tendencia clara en los niveles de concentración de gases. La componente estacional revela patrones repetitivos que corresponden a los ciclos diarios de actividad urbana (horas pico de tráfico), mientras que los residuos muestran una varianza controlada tras la limpieza de datos.




Ilustración. 3.
Gráficas de descomposición estacional

B. Modelado ARIMA y Pronóstico

El modelo ARIMA fue ajustado para predecir el comportamiento de las concentraciones de gases (específicamente la columna analizada, como PT08.S2). Los resultados del pronóstico para los próximos 30 períodos muestran una estabilización en la media, con un intervalo de confianza del 95% que se ensancha conforme aumenta el horizonte de tiempo, lo cual es esperado en modelos estocásticos. Este comportamiento se puede observar en las ilustraciones 4 y 5




Ilustración. 4.
Gráficas de predicciones ARIMA vs Datos reales




Ilustración. 5.
Pronóstico a 30 períodos con intervalos de confianza

A continuación, se presenta una muestra de los valores proyectados obtenidos:

Tabla 1.
Tabla de valores proyectados

Pe- ríodo	Valor Pronosticado (Mean)	Límite Inferior (95%)	Límite Superior (95%)
3000	1048.21	830.56	1265.87
3001	1045.85	690.87	1400.83
3002	1046.07	597.31	1494.83
...	...	...	...

El análisis de la serie temporal permitió identificar que la calidad del aire no es aleatoria, sino que obedece a ciclos temporales predecibles. La correcta implementación de la interpolación temporal fue clave, ya que eliminar registros con errores habría roto la continuidad necesaria para el modelo ARIMA.

Se concluye que, aunque el modelo captura la tendencia central, la volatilidad inherente a los factores climáticos y sociales sugiere que para aplicaciones de alta precisión se podrían explorar modelos tipo SARIMA (estacionales) o redes neuronales recurrentes (LSTM) en trabajos futuros.

3.3 Resultados Actividad 3

La implementación permitió convertir exitosamente una fuente web no estructurada en un conjunto de datos analíticamente útil.

Se obtuvieron los siguientes resultados:

- Extracción completa de la jerarquía del artículo.
- Recuperación del contenido textual relevante sin etiquetas HTML residuales.
- Identificación automática de entidades semánticas mediante PLN.
- Organización de la información en un formato JSON estructurado.
- Generación de un archivo reutilizable para tareas de minería de datos o análisis exploratorio.

El proceso desarrollado demuestra la viabilidad de integrar técnicas de Web Scraping y PLN dentro de un mismo flujo de análisis de datos, permitiendo transformar información pública en datasets estructurados con valor analítico.

3.4 Resultados Actividad 4

Entonces, con lo obtenido en el análisis del boletín oficial, podemos observar en la **tabla 1** muestra el conteo por tipo de mandato, observamos que la mayoría de los mandatos que se trataron en ese día fueron las resoluciones, seguido por los anuncios, y finalmente por mandatos jurisprudenciales.

Tabla 1. Conteo por tipo de mandato

Tipo	Conteo
Resolución	143
Anuncio	74
Judicial	64
Orden	5
Otro	3
Acuerdo	1
Enmienda	1

Mediante las siguientes, figuras, podemos observar esta misma tendencia, mostrándose que la mayoría de los mandatos para la fecha mencionada fueron resoluciones. En la **ilustración 3**, se muestra la tendencia hacia las resoluciones. Este tipo de comportamiento es el cotidiano, por lo general, las asambleas diariamente muestran o emiten resoluciones. La teoría se sustenta además por que el segundo tipo de mandato común fueron los anuncios, que están estrechamente relacionados con la transparencia. La parte de justicia implica edictos, notificaciones de procedimientos, citaciones. Así que

el día 2 de febrero del 2026, se resume en que se trabajó en mandatos administrativos, procedimientos informativos y judiciales que en mandatos fuertes.

En la ilustración 4, podemos observar la proporción de los mandatos en ese día y se puede apreciar con otra perspectiva, el cómo las resoluciones, anuncios y de justicia fueron los mandatos más comunes para ese día en específico.




Ilustración. 3.

La gráfica muestra una tendencia clara de sesgo con respecto a las resoluciones, es decir, en ese día hubo muchas más resoluciones que enmiendas, leyes o acuerdos.




Ilustración. 4.

La gráfica muestra la tendencia de la cantidad de resoluciones aprobadas y que fue de los mandatos que más se hicieron para el día 2 de febrero, seguido por los anuncios y las órdenes judiciales, implicando la poca acción a mandatos fuertes para ese día

4 Conclusiones

Por otro lado, la transición hacia datos no estructurados y semi-estructurados (Actividades 3 y 4) Mientras que el modelo ARIMA permite una predicción cuantitativa, el uso de spaCy y lxml permite una comprensión cualitativa y estructural que el análisis puramente numérico no alcanza. Se discute que, aunque las herramientas utilizadas son robustas, la precisión de los resultados depende críticamente de la comprensión del dominio de los datos, ya sea para ajustar parámetros en un modelo climático o para mapear espacios de nombres en un documento legal.

El desarrollo de esta práctica permitió validar la versatilidad de Python como herramienta central para la ingeniería y análisis de datos, además de que se observó que el desafío principal no reside únicamente en la aplicación de modelos, sino en la preparación adecuada de los datos. De la Actividad 1 y 2, se concluye que la combinación de consultas estructuradas y modelos estadísticos permite identificar patrones estacionales y tendencias comerciales con alta fidelidad, sin embargo, la integridad de la base de datos y la correcta interpolación de valores fueron determinantes para obtener visualizaciones y pronósticos coherentes. De la Actividad 3 y 4, se destaca que el enriquecimiento de datos mediante PLN y la extracción mediante XPath son pasos esenciales para estructurar la información masiva disponible en la web y en archivos oficiales, adicionalmente reveló la complejidad de las estructuras jerárquicas y semánticas, que difícilmente se pueden cuantizar. Como aprendizaje general, se establece que el procesamiento de datos debe ser un proceso iterativo y multimodular: la limpieza, la comprensión del problema, la detección de atípicos y la correcta selección de herramientas de análisis son los pilares que garantizan la generación de conocimiento útil. Este enfoque integral prepara al analista para enfrentar retos reales donde la información rara vez se presenta en un formato único o ideal.

References

1. Rocha, L.: Chinook SQLite Database. GitHub Repository, https://github.com/lerocha/chinook-database/blob/master/ChinookDatabase/DataSources/Chinook_Sqlite.sqlite, last accessed 2026/02/14.
2. UCI Machine Learning Repository: Air Quality Dataset. University of California, Irvine, <https://archive.ics.uci.edu/ml/datasets/Air+Quality> (archive.ics.uci.edu in Bing), last accessed 2026/02/14.
3. Wikipedia contributors: Python. In: Wikipedia, The Free Encyclopedia, <https://es.wikipedia.org/wiki/Python>, last accessed 2026/02/14.
4. Boletín Oficial del Estado: API de datos abiertos – Sumario 2026/02/02. Gobierno de España, <https://boe.es/datosabiertos/api/boe/sumario/20260202>, last accessed 2026/02/14.